

Previsión de la demanda para dimensionar el *stock* de un almacén



Universitat Oberta
de Catalunya

Marcos Rodríguez Soler

*Data analytics in Industrial and
Business Environments*

Máster Universitario en Ciencia de
Datos

Nombre de la directora del TF:
Lorena Polo Navarro

Nombre de la PRA:
Susana Acedo Nadal

24 de mayo de 2026



Esta obra está sujeta a una licencia de Reconocimiento

<https://creativecommons.org/licenses/by-nc/3.0/es/>

Ficha del trabajo final

Título del trabajo:	Previsión de la demanda para dimensionar el <i>stock</i> de un almacén
Nombre del autor:	Marcos Rodríguez Soler
Nombre del director/a de TF:	Lorena Polo Navarro
Fecha de entrega:	24 de mayo de 2026
Titulación:	Máster Universitario en Ciencia de Datos
Área del Trabajo Final:	<i>Data Analytics in Industrial and Business Environments</i>
Idioma del trabajo:	Castellano
Palabras clave:	Ciencia de datos, logística, series temporales, <i>machine learning</i> , previsión de la demanda, <i>industrial forecasting</i> , <i>supply chain</i> .

Resumen

El presente trabajo aplica los conocimientos adquiridos en el Máster Universitario en Ciencia de Datos a un problema real al que se enfrentan numerosas empresas: la gestión eficiente del inventario. Con este propósito, se ha desarrollado un modelo de previsión de la demanda orientado a mejorar cuantitativamente la gestión de *stocks*, reduciendo la brecha entre la precisión predictiva y el desempeño económico del negocio.

En este contexto, se han implementado diversos modelos de aprendizaje automático, junto con un modelo base de tipo *naive*, para pronosticar la demanda de artículos de una empresa del sector de la automoción. Las predicciones obtenidas se han integrado en una política de reposición *Order-Up-To* (R, S), que incorpora el *lead time* y el cálculo del *stock* de seguridad. A través de la simulación dinámica del sistema de inventario, se ha cuantificado el impacto económico de cada enfoque en términos de costes de almacenamiento y roturas de *stock*, así como del nivel de servicio alcanzado.

Los resultados muestran que el uso de modelos de aprendizaje automático permite reducir significativamente los costes totales del sistema frente a enfoques más simples, evidenciando el valor añadido de la analítica avanzada en la toma de decisiones operativas. Asimismo, también se demuestra la importancia de evaluar los modelos predictivos no solo en términos de error, sino también en función de su impacto en el rendimiento del negocio.

Este trabajo sienta las bases para la incorporación futura de técnicas de previsión probabilística y análisis de escenarios, con el fin de reforzar la robustez del sistema ante distintos niveles de incertidumbre en un sector donde la anticipación a lo inesperado resulta clave.

Abstract

The present work applies the knowledge acquired during the Master's Degree in Data Science to a real-world problem faced by numerous companies: efficient inventory management. To this end, a demand forecast model has been developed to quantitatively improve stock management, reducing the gap between predictive accuracy and the economic performance of the business.

Within this framework, multiple machine learning algorithms have been developed alongside a baseline naïve model to forecast the demand for products in an automotive company. The resulting predictions have been integrated into an Order-Up-To (R, S) replenishment policy, which incorporates lead time and safety stock calculations. Through the dynamic simulation of the inventory system, the economic impact of each approach has been quantified in terms of holding costs, stockout costs, and the achieved service level.

The results show that the use of machine learning models significantly reduces the total system costs compared to simpler approaches, highlighting the added value of advanced analytics in operational decision-making scenarios. Furthermore, the work demonstrates the importance of evaluating predictive models not only in terms of error metrics, but also based on their impact on business performance.

This work lays the foundation for the future incorporation of probabilistic forecasting techniques and scenario analysis, with the aim of enhancing system robustness under different levels of uncertainty in a sector where anticipating the unexpected is crucial.

Índice general

1	Introducción	10
1.1	Contexto y justificación del trabajo	10
1.2	Objetivos del trabajo	12
1.2.1	Objetivo general	12
1.2.2	Objetivos específicos	12
1.3	Enfoque y método seguido	12
1.4	Planificación del trabajo	14
1.5	Impacto en sostenibilidad, ético-social y de diversidad	16
1.6	Breve resumen de los productos obtenidos	17
1.7	Breve descripción de las otras secciones de la memoria	17
2	Revisión bibliográfica	19
2.1	Marco conceptual	19
2.1.1	Gestión de inventarios y previsión de la demanda	19
2.1.2	Políticas de reposición y nivel de servicio	20
2.1.3	Modelos de series temporales	21
2.1.4	Modelos de aprendizaje automático	22
2.1.5	Métricas de evaluación del error	26
2.2	Estado del arte	27
2.2.1	Descripción de publicaciones relacionadas con la temática	28
2.2.2	Tabla resumen	31
2.2.3	Conclusiones del estado del arte	34
3	Diseño e implementación del trabajo	35
3.1	Origen de los datos	35
3.1.1	Obtención	35
3.1.2	Descripción	35
3.1.3	Carga	36
3.2	Exploración de los datos	36
3.2.1	Resumen	38
3.2.2	Análisis de la calidad de los datos	38
3.2.3	Análisis estadístico	44
3.3	Preparación de los datos	44
3.3.1	Limpieza	44
3.3.2	Transformación	48

3.4	<i>Clustering</i>	48
3.4.1	Construcción de variables por producto	49
3.4.2	Escalado estándar	49
3.4.3	Selección del parámetro k	50
3.4.4	Aplicación y visualización de los <i>clusters</i>	50
3.4.5	Interpretación de los <i>clusters</i>	51
3.5	Ingeniería de características	53
3.6	Modelado	55
3.6.1	Selección de los modelos	55
3.6.2	Definición de los indicadores de precisión	56
3.6.3	Preprocesamiento específico de los modelos	57
3.6.4	Definición de los periodos de entrenamiento y validación	58
3.6.5	Elección de hiperparámetros	59
3.7	Evaluación de los modelos	62
3.7.1	Análisis de los resultados de precisión obtenidos	62
3.7.2	Conclusiones de los resultados obtenidos	66
3.8	Evaluación del impacto económico	67
3.8.1	Simulación del inventario bajo una política de reposición <i>Order-Up-To</i> (R, S)	67
3.8.2	Análisis de los resultados de las simulaciones	70
3.8.3	Conclusiones de la evaluación económica	71
4	Conclusiones	72
4.1	Lecciones aprendidas	72
4.2	Logro de los objetivos	72
4.3	Seguimiento de la planificación y la metodología	73
4.4	Limitaciones del trabajo	74
4.5	Líneas de trabajo futuro	75
5	Bibliografía	76
6	Glosario	80
A	Anexo	81
A.1	Herramientas para la realización del trabajo	81
A.2	Reconstrucción de <i>bolOpen</i> y <i>bolHoliday</i>	81
A.3	Detalles de la optimización de los hiperparámetros	83
A.4	Visualización de la demanda y del inventario simulado	85

Índice de figuras

1.1	Evolución de la contribución al PIB español de varios sectores desde el año 1850 hasta el 2011 [1].	10
1.2	Ciclo de un proyecto de minería de datos según la metodología CRISP-DM [3].	13
1.3	Diagrama de <i>Gantt</i> de la planificación del proyecto.	15
1.4	ODS alineados con el trabajo.	17
2.1	Pronóstico probabilístico de la inflación del <i>Bank of England</i> en el año 2013 representado mediante intervalos de predicción para distintos niveles de probabilidad [5].	19
2.2	Descomposición de una serie temporal en sus componentes: serie original (<i>data</i>), tendencia general (<i>trend</i>), componente estacional (<i>seasonal</i>), y residuo (<i>remainder</i>) [9].	21
2.3	Ejemplo de la estructura de un árbol de decisión para una tarea de regresión, donde los círculos azules representan los nodos hoja, los blancos se corresponden con los nodos internos, y el círculo superior es el nodo raíz [16].	23
2.4	Arquitectura de una celda LSTM [17].	25
2.5	Número de publicaciones científicas en el ámbito de la previsión de la demanda en la década del 2010 [30].	28
2.6	Ejemplo del enriquecimiento de un conjunto de datos para la previsión de la demanda con variables exógenas [33].	29
2.7	Arquitectura de una herramienta de decisión para la gestión de inventarios dinámicos [34].	30
3.1	Distribuciones de las variables.	39
3.2	<i>Boxplots</i> de las variables numéricas.	40
3.3	Demanda y <i>stock</i> disponible de varios productos.	41
3.4	Calendario operativo de la empresa de productos automovilísticos a lo largo de todo el horizonte temporal de sus productos. Los recuadros rojos referencian los domingos, los cuadrados morados se corresponden con los días que la empresa reconoce como festivos, las casillas blancas indican que el establecimiento no abrió sus puertas, y las cuadrículas negras se corresponden con las fechas en las que la tienda sí abrió.	42
3.5	<i>Boxplot</i> de la fracción de roturas de <i>stock</i> totales en cada producto.	43
3.6	Calendario reconstruido de la compañía.	45
3.7	Variable <i>udsVenta</i> antes y después del proceso de interpolación lineal de varios productos.	46

3.8	<i>Boxplot</i> de la fracción de roturas de <i>stock</i> iniciales para cada producto. . . .	47
3.9	Ejemplos de la demanda histórica de varios productos distintos entre sí. . . .	48
3.10	Suma de los errores cuadrados en función del número de <i>clusters</i>	50
3.11	Proyección de los grupos obtenidos con <i>k-means</i> con PCA (a) y t-SNE (b)	50
3.12	(a) Diferencias entre los <i>clusters</i> y la media de todos los productos. (b) Tamaño de cada <i>cluster</i>	51
3.13	Proyección de los <i>clusters</i> fusionados finales con PCA (a) y t-SNE (b)	52
3.14	Matriz de correlaciones de las variables explicativas y los atributos objetivo, <i>hor_j</i> , del conjunto de datos global. Solo se muestran algunos atributos por cuestión de espacio.	54
3.15	Generación de los conjuntos en <i>Random Forest</i> (a) , y en <i>XGBoost</i> y LSTM (b)	58
3.16	Validación temporal empleada durante la optimización de los hiperparáme- tros.	60
3.17	Arquitectura de la red LSTM empleada en el proyecto.	61
3.18	Importancia de las variables del conjunto de aprendizaje en las decisiones del modelo global <i>Random Forest</i>	64
3.19	Demanda real frente algunas predicciones de dos productos del <i>cluster</i> <i>top_ventas</i> mediante <i>Random Forest</i> (a-b) , <i>XGBoost</i> (c-d) , y LSTM (e-f)	65
A.1	Demanda real y unidades de dos ítems, calculadas con los resultados del mejor modelo global (a-b) , de los mejores modelos por grupo (c-d) , y del modelo <i>naive</i> (e-f)	85

Índice de tablas

1	Planificación temporal del proyecto.	16
2	Contribuciones científicas al campo de la previsión de la demanda.	32
3	Resumen del contenido del conjunto de datos integrado.	37
4	Estadísticos descriptivos de las variables numéricas.	44
5	Resumen del contenido del agregado por producto.	49
6	Resumen de los cuatro grupos finales obtenidos tras el proceso de <i>clustering</i>	52
7	Resumen de las variables derivadas añadidas al conjunto de datos.	53
8	Hiperparámetros seleccionados y optimizados para <i>Random Forest</i>	59
9	Hiperparámetros seleccionados y optimizados para <i>XGBoost</i>	60
10	Hiperparámetros seleccionados y optimizados para LSTM.	62
11	Métricas de evaluación del error obtenidas por los distintos modelos.	63
12	Resultados de las simulaciones del inventario. Los costes se expresan en euros.	70
13	Versiones de las soluciones de <i>software</i> empleadas en el trabajo.	81
14	Festividades y aperturas del punto de venta de la empresa de marzo de 2024 hasta marzo de 2025.	82
15	Resultados de la optimización de los hiperparámetros del modelo <i>Random Forest</i>	84
16	Resultados de la optimización de los hiperparámetros del modelo <i>XGBoost</i>	84
17	Resultados de la optimización de los hiperparámetros del modelo LSTM.	84

1 Introducción

1.1 Contexto y justificación del trabajo

La segunda revolución industrial supuso una transformación profunda en la industria de la manufactura, impulsando la producción en serie y la introducción de la cadena de montaje. Durante esa época, las economías más desarrolladas del mundo eran aquellas que presentaban una gran capacidad de producción industrial. Sin embargo, en los tiempos modernos ha tenido lugar un cambio de paradigma en cuanto al tipo de sector que hace de motor de las principales potencias mundiales. En este sentido el sector de servicios ha experimentado un crecimiento sostenido durante las últimas décadas, convirtiéndose en una de las principales fuentes de empleo y generación de valor añadido. Esto mismo se puede observar en la propia economía española en la Figura 1.1, donde se ha producido una transformación estructural donde el sector de servicios ha incrementado progresivamente su participación en el PIB, mientras que el peso relativo de la industria se ha reducido [1].



Figura 1.1: Evolución de la contribución al PIB español de varios sectores desde el año 1850 hasta el 2011 [1].

No obstante, el papel de la industria manufacturera sigue siendo fundamental para el funcionamiento de las economías modernas. Sectores como la alimentación, la automoción, la fabricación de maquinaria o la microelectrónica no solo sostienen cadenas de suministro críticas, sino que constituyen fuentes esenciales de innovación, productividad y empleo [2].

En este contexto, uno de los principales retos a los que se enfrentan las empresas de este sector es la gestión de inventarios eficiente, donde cualquier imprevisto puede desencadenar pérdidas económicas importantes. El inventario representa una parte significativa del

capital de las empresas y constituye un activo estratégico cuya administración correcta influye directamente en la rentabilidad y la competitividad. Consecuentemente, la toma de decisiones en inventario es una tarea muy compleja donde se debe hallar un equilibrio entre disponer de niveles excesivos e insuficientes de *stock*. Esto implica balancear capital inmovilizado, costes de almacenamiento y riesgo de obsolescencia, con el deterioro de la imagen corporativa y la insatisfacción del cliente.

Uno de los factores que más condiciona el dimensionamiento del inventario es la incertidumbre asociada a la demanda futura. Cuando una empresa realiza un pedido a su proveedor, los productos no se reciben de forma inmediata, sino tras un determinado periodo de tiempo denominado *lead time*. Durante ese intervalo, la empresa debe seguir atendiendo la demanda de sus clientes sin disponer aún del nuevo suministro y evitar un agotamiento de existencias, fenómeno conocido como una rotura de *stock* o *stockout*. Para evitar las pérdidas económicas asociadas a este suceso, las organizaciones mantienen un margen adicional de inventario conocido como *stock* de seguridad. Por lo tanto, la calidad de la previsión de esta demanda futura resulta un elemento crítico para la gestión eficiente de los sistemas de inventario.

Para hacer frente a esta problemática, las empresas han empleado modelos estadísticos de series temporales para anticipar la demanda. No obstante, en la última década las organizaciones han empezado a usar el dato como un activo crucial dentro de su dinámica operativa. Esto ha propiciado la inclusión de nuevas variables para abordar este problema, de manera que actualmente se dispone de un amplio abanico de posibilidades para mejorar la precisión predictiva. Por consiguiente, es de esperar que en los años recientes el interés en la aplicación de métodos basados en datos en este tipo de problemas se haya disparado.

Así pues, el presente trabajo se enmarca en este contexto, y su motivación surge de la necesidad de conectar la mejora en la capacidad predictiva con la toma de decisiones en inventario y su impacto económico asociado. Más allá de comparar modelos de previsión, se pretende analizar cómo la elección del enfoque predictivo influye en el dimensionamiento del inventario, en el nivel de servicio ofrecido y en el coste total del sistema. De este modo, se pretende combinar métodos de ciencia de datos con fundamentos de gestión logística para una toma de decisiones más informada y alineada con los objetivos estratégicos de las empresas. Además, también existe una motivación personal relacionada con el sector de la industria química, que es mi *background* académico, el cual se está digitalizando de forma paulatina. En este contexto, la incorporación de almacenes inteligentes es un tema de actualidad. Este proceso debe comportar una renovación integral de la cadena de suministro, de manera que el presente proyecto puede aportar algunas de las bases para el inicio de la transformación de estas organizaciones que tocan tan de cerca en mi caso.

1.2 Objetivos del trabajo

Tras haber presentado el contexto en el que se enmarca el presente trabajo y la problemática que se pretende abordar, a continuación se establece el objetivo general que se desea alcanzar, así como una serie de objetivos específicos que, en su conjunto, permiten desarrollar y materializar dicho propósito.

1.2.1. Objetivo general

La principal finalidad del presente proyecto es el desarrollo de un modelo de previsión de la demanda para la gestión de inventario que permita alinear el *stock* con la demanda, fundamentándose en datos y en modelos de aprendizaje automático que permitan conectar la mejora en la precisión predictiva con su impacto económico.

1.2.2. Objetivos específicos

Para cumplir con las expectativas generales, es necesario alcanzar los siguientes objetivos concretos en el orden en el que se plantean.

1. Analizar la problemática de la gestión de inventarios desde una perspectiva empresarial, identificando las variables clave que conectan la previsión de la demanda con el rendimiento económico del negocio.
2. Analizar, preprocesar y explorar los datos históricos de la demanda así como las demás variables adicionales relevantes.
3. Implementar modelos de *machine learning* y un modelo base *naive*, y evaluar sus rendimientos con métricas estándar.
4. Estimar la incertidumbre asociada a cada modelo predictivo e integrarla en una política de reposición tipo *Order-Up-To* (R, S) para simular el comportamiento del sistema de inventario.
5. Analizar el impacto económico de los distintos modelos de *machine learning* y compararlo con un enfoque simple dado por un modelo *naive*. También se pretende evaluar el nivel de servicio alcanzado en cada enfoque.

1.3 Enfoque y método seguido

El cumplimiento de los objetivos específicos definidos en el apartado anterior se estructura alrededor del ciclo de vida del dato, ya que cada uno de ellos puede asociarse a una etapa concreta de este. Consecuentemente, el trabajo presente se ha desarrollado siguiendo la

metodología CRISP-DM [3], ya que se trata de uno de los enfoques más ampliamente aceptados en proyectos de análisis y minería de datos.

Esta metodología define las distintas fases de un proyecto del ámbito de la ciencia de datos ilustradas en la Figura 1.2, las cuales son el entendimiento del negocio, el entendimiento de los datos, la preparación de los datos, el modelado, la evaluación, y el despliegue. Cada una de estas etapas se puede asociar a los distintos objetivos específicos planteados.



Figura 1.2: Ciclo de un proyecto de minería de datos según la metodología CRISP-DM [3].

Entendimiento del negocio

Esta fase conlleva una revisión bibliográfica exhaustiva, desarrollada en la segunda sección del documento, con el objetivo de comprender el entorno en el que se debe encuadrar el proyecto. Dentro del contexto del presente trabajo, esta etapa coincide con el primer objetivo específico planteado, ya que el proyecto se acota a la necesidad de conectar la precisión predictiva con su impacto económico real.

Entendimiento de los datos

La siguiente etapa del CRISP-DM comporta la analítica de los datos disponibles para comprender su estructura y comportamiento. Esto se corresponde con el análisis exploratorio que se aplica a los conjuntos de datos históricos de la demanda. Por lo tanto, esta fase se corresponde con la primera parte del segundo objetivo específico dedicada a la exploración de los datos.

Preparación de los datos

En esta fase se llevan a cabo las tareas necesarias para preparar los datos para la siguiente etapa, incluyendo los procesos de limpieza, transformación y tratamiento de valores nulos. Así pues, este proceso comprende el resto de las operaciones que se deben

realizar a lo largo del segundo objetivo específico, con el fin de garantizar que las comparaciones entre modelos tengan lugar bajo las mismas condiciones.

Modelado

El proceso de modelado consiste en implementar los modelos seleccionados sobre los datos, fase que se corresponde directamente con el tercer objetivo específico, donde se evalúa el rendimiento de algoritmos de aprendizaje automático y de un modelo *naive*.

Evaluación

En esta fase de la metodología CRISP-DM se analizan los resultados obtenidos de la etapa de modelado, no solo desde un punto de vista predictivo, sino también económico. Esto mismo se corresponde con el cuarto y quinto objetivo descritos, donde se integran las previsiones generadas en una política de reposición *Order-Up-To* (R, S), para simular el comportamiento del sistema de inventario y cuantificar los costes y el nivel de servicio alcanzado.

Despliegue

La última etapa de la metodología consiste en el despliegue de los modelos entrenados para incorporarlos en de la dinámica operativa de la empresa. No obstante, esta etapa queda fuera del alcance de los objetivos planteados, por lo que se ha optado por no desarrollarla en el presente trabajo.

1.4 Planificación del trabajo

El proyecto se desarrolla en un conjunto de entregables que se evalúan de forma periódica y que sirven para elaborar el diagrama de *Gantt* de la Figura 1.3. Este gráfico permite entender el volumen de trabajo y tiempo que se ha dedicado a cada sección. Para facilitar la planificación de cada tarea concreta, algunos de los entregables se dividen en distintos hitos que se asignan a un periodo de tiempo concreto.

En primer lugar, se aborda la definición y planificación del proyecto, donde se delimitan los objetivos y se establece el cronograma del trabajo (**H1**). A continuación, se lleva a cabo una revisión del estado del arte con el fin de contextualizar la problemática y fundamentar metodológicamente el estudio (**H2**). La fase central del proyecto corresponde al diseño e implementación, empezando por el procesamiento de los datos, que incluye el análisis exploratorio y el preprocesamiento de la información histórica de demanda (**H3**).




Figura 1.3: Diagrama de *Gantt* de la planificación del proyecto.

Posteriormente, se prosigue con el entrenamiento de los modelos de *machine learning* y del modelo base *naive* para la previsión de la demanda (**H4**). Durante esta fase también se lleva a cabo el ajuste de hiperparámetros y la evaluación de distintas configuraciones de los modelos entrenados. A continuación, se realiza el análisis de los resultados obtenidos mediante las métricas de precisión calculadas, y se integran los modelos en una política de reposición de tipo *Order-Up-To* (R, S) para simular el comportamiento del sistema de inventario (**H5**). En esta etapa también se calculan los costes operativos asociados al almacenamiento y las roturas de *stock*, así como el nivel de servicio alcanzado por cada estrategia predictiva. De forma paralela al desarrollo técnico, también tiene lugar la redacción progresiva de la memoria (**H6**), incluyendo la documentación de la metodología empleada, los resultados obtenidos y las conclusiones del trabajo. Finalmente, el proyecto culmina con la preparación de la presentación audiovisual (**H7**) y la defensa del trabajo ante un tribunal (**H8**). Asimismo, para un mayor nivel de detalle en cuanto a la duración de cada hito, la Tabla 1 muestra la duración aproximada de cada uno de ellos.

Por último, es importante destacar el hecho de que este proceso es iterativo. Consecuentemente, a medida que se avance en cada una de las secciones prácticas que componen el proyecto, muy posiblemente sea necesario retroceder a fases anteriores para modificar algunos de los apartados previos en función de cómo se desarrolle el trabajo. Esto no se ve reflejado ni en la Figura 1.3 ni en la Tabla 1, pero es una práctica habitual en los proyectos de ciencia de datos.

Tabla 1: Planificación temporal del proyecto.

Nombre de la tarea	Duración	Comienzo	Fin
PROYECTO			
H1. Definición y planificación	9 días	mié 18/02/26	dom 01/03/26
H2. Estado del arte	16 días	lun 02/03/26	dom 22/03/26
Diseño e implementación	35 días	lun 23/03/26	dom 10/05/26
H3. Procesar los datos	5 días	lun 23/03/26	dom 29/03/26
H4. Usar los datos	5 días	lun 30/03/26	dom 05/04/26
H5. Analizar los resultados	25 días	lun 06/04/26	dom 10/05/26
H6. Redacción de la memoria	68 días	mié 18/02/26	dom 24/05/26
Redacción de la memoria (pre.)	64 días	mié 18/02/26	dom 17/05/26
Redacción de la memoria (final)	6 días	lun 18/05/26	dom 24/05/26
H7. Presentación audiovisual	7 días	lun 25/05/26	mar 02/06/26
H8. Defensa del trabajo	1 día	mié 03/06/26	mié 03/06/26

1.5 Impacto en sostenibilidad, ético-social y de diversidad

Los proyectos de ciencia de datos no solo implican operaciones técnicas y labores de ingeniería, sino que también deben construirse alrededor de una reflexión sobre su impacto en términos de sostenibilidad, ética y diversidad. En este sentido, el presente trabajo se plantea considerando su contribución potencial al desarrollo sostenible, así como el cumplimiento de los principios éticos en el tratamiento de datos, y con un enfoque inclusivo en el diseño de la propuesta.

Desde la perspectiva de la sostenibilidad, el proyecto se alinea con varios ODS de la Agenda 2030 de las Naciones Unidas [4], tal y como se muestra en la Figura 1.4. En primer lugar, contribuye al ODS 9 (Industria, innovación e infraestructura), ya que el objetivo principal es la mejora de procedimientos industriales relacionados con la gestión logística mediante la aplicación de métodos del ámbito de la ciencia de datos. Asimismo, el trabajo también guarda relación con el ODS 12 (Producción y consumo responsables), ya que una gestión más eficiente del inventario permite reducir el exceso de *stock* y optimizar el uso de recursos empresariales. De forma indirecta, también se vincula con el ODS 8 (Trabajo decente y crecimiento económico), al favorecer la eficiencia operativa y la sostenibilidad económica de las organizaciones mediante decisiones fundamentadas en datos.



Figura 1.4: ODS alineados con el trabajo.

En cuanto a las consideraciones éticas, el trabajo se desarrolla respetando los principios establecidos por el comité ético de la universidad. En este sentido, el análisis se basa exclusivamente en datos históricos de demanda sin información personal identificable, y no se ha requerido la participación de sujetos humanos ni el tratamiento de datos sensibles.

Por último, en relación con la diversidad y la inclusión, también se tiene en cuenta la importancia de evitar cualquier sesgo derivado del uso de datos históricos, a pesar de que el proyecto no se focaliza en el estudio de variables demográficas. Asimismo, el objetivo del trabajo propuesto se concibe como un sistema de apoyo a la decisión accesible y comprensible para cualquier perfil profesional dentro de una empresa.

1.6 Breve resumen de los productos obtenidos

En el presente trabajo se ha desarrollado un sistema de previsión de la demanda orientado a la gestión de inventarios basado en técnicas de aprendizaje automático. Se ha implementado una metodología completa que abarca desde el preprocesado y análisis de los datos hasta el entrenamiento y evaluación de distintos modelos predictivos.

Asimismo, se ha integrado la incertidumbre asociada a las predicciones dentro de una política de reposición de tipo *Order-Up-To* (R, S). Esto ha permitido simular el comportamiento del sistema de inventario, analizar el impacto económico derivado, y compararlo con el rendimiento de un modelo base *naive*.

1.7 Breve descripción de las otras secciones de la memoria

La presente memoria del trabajo se ha estructurado en un conjunto de secciones, donde en cada una de ellas se trabaja para lograr un objetivo específico concreto y que, a su vez, puede contener múltiples hitos de la Figura 1.3.

En el capítulo 2. *Revisión bibliográfica* se introducen los conceptos teóricos fundamentales necesarios para comprender tanto el contexto del proyecto como su desarrollo. También se incluye una revisión de la literatura científica en el ámbito de la previsión de la demanda,

con el objetivo de contextualizar el estado del arte de la problemática.

Seguidamente, en el apartado *3. Diseño e implementación* se describe el desarrollo práctico del proyecto, incluyendo las distintas etapas del proceso, tales como la limpieza y preprocesado de los datos, el desarrollo de los modelos predictivos, y su evaluación económica.

Acto seguido, en el capítulo *4. Conclusiones* se presentan las principales deducciones derivadas del trabajo, destacando las lecciones aprendidas a lo largo del proyecto, las limitaciones identificadas, y posibles líneas de investigación futura.

En la sección *5. Bibliografía* se incluyen todas las fuentes de información consultadas para la elaboración del trabajo.

De forma adicional, en el apartado *6. Glosario* se ha añadido un diccionario con los significados de las abreviaciones empleadas en el trabajo.

Por último, en el capítulo *A. Anexo* se incorporan materiales complementarios que apoyan el desarrollo del proyecto, como detalles técnicos, resultados adicionales o información relevante que no se ha incluido en el cuerpo principal del documento.

2 Revisión bibliográfica

2.1 Marco conceptual

El presente trabajo se centra en la aplicación de métodos basados en datos para la previsión de la demanda en el contexto de la gestión de la cadena de suministro. En este sentido, resulta necesario establecer los fundamentos teóricos básicos de cada componente del proyecto, incluyendo los conceptos clave de gestión de inventarios, las políticas de reposición, y los principales modelos de previsión empleados a lo largo de la historia. Este marco conceptual permite comprender la metodología desarrollada y facilita la comprensión de los resultados obtenidos.

2.1.1. Gestión de inventarios y previsión de la demanda

Tal y como se anticipaba en la introducción, la previsión de la demanda es un gran reto al que se enfrentan las empresas de la industria manufacturera en su día a día, de manera que aquellas que realizan buenas previsiones tienen una gran ventaja competitiva sobre aquellas cuyos pronósticos fallan. Este proceso consiste en estimar la cantidad de productos o servicios que los clientes solicitarán en un periodo futuro utilizando toda la información disponible, incluyendo tanto datos históricos como el conocimiento de cualquier evento futuro que pueda impactar dichas predicciones.




Figura 2.1: Pronóstico probabilístico de la inflación del *Bank of England* en el año 2013 representado mediante intervalos de predicción para distintos niveles de probabilidad [5].

Dada la importancia de estos pronósticos, la literatura especializada ha desarrollado distintos enfoques para llevarlos a cabo. Estas estrategias pueden clasificarse según la información que proporcionan del futuro, dando lugar a distintos tipos de pronósticos. El más simple de todos es la previsión puntual, que consiste en un valor único que representa la estimación de la demanda para un periodo futuro [6]. No obstante, suele preferirse el pronóstico probabilístico porque en lugar de ofrecer un solo número, proporciona una des-

cripción de los posibles escenarios de la demanda mediante distribuciones de probabilidad [5]. Una forma habitual de representar este tipo de previsiones es mediante los *fan charts*, que muestran distintos intervalos de predicción alrededor de la estimación central, como se observa en la Figura 2.1.

Por último, la estrategia *multi-step* permite generar previsiones para más de un periodo futuro, hecho que resulta especialmente útil en contextos donde las decisiones operativas deben anticiparse con suficiente antelación [2]. Este enfoque resulta particularmente relevante en los entornos logísticos, donde las decisiones de reposición deben considerar el tiempo de entrega de los productos por parte de los proveedores.

2.1.2. Políticas de reposición y nivel de servicio

La gestión de inventarios constituye un elemento clave en la cadena de suministro, ya que permite garantizar la disponibilidad de los productos para satisfacer la demanda y minimizar los costes asociados al almacenamiento y a las roturas de *stock*. En este contexto, las políticas de reposición establecen las reglas que determinan cuándo y cuánto inventario reponer.

Entre las distintas políticas existentes, una de las más utilizadas es la política de inventarios *Order-Up-To* (R, S). En este enfoque, el estado del inventario se revisa en intervalos de tiempo fijos, R , y en cada revisión se evalúa si es necesario realizar un pedido de cantidad variable con el objetivo de elevar la posición de inventario, PI , hasta un nivel objetivo, S . En este contexto, la posición de inventario se calcula con la Ecuación 1, como la suma del *stock* disponible en el almacén, $U_{almacen}$, y las unidades asociadas a los pedidos en tránsito a los proveedores, $U_{pedidos}$ [6].

$$PI = U_{almacen} + U_{pedidos} \quad (1)$$

El comportamiento de esta política depende de la incertidumbre de la demanda y del tiempo de entrega, L . En este contexto, el intervalo $R + L$ se conoce como ciclo de aprovisionamiento, y representa el tiempo durante el cual el sistema debe satisfacer la demanda antes de recibir un nuevo pedido. Por este motivo, el nivel objetivo de inventario se calcula con la Ecuación 2, como la suma de la demanda esperada durante dicho intervalo, $\hat{y}_{R+L}$, y un *stock* de seguridad, SS , destinado a absorber variaciones inesperadas de la demanda [7].

$$S = \hat{y}_{R+L} + SS \quad (2)$$

$$SS = k \cdot \sigma_{R+L} \cdot \sqrt{R+L} \quad (3)$$

El inventario de seguridad permite controlar el riesgo de las roturas de *stock* asociado a la incertidumbre de la demanda. Como muestra la Ecuación 3, su cálculo depende de la variabilidad de la demanda durante el periodo de protección, σ_{R+L} , y del factor de servicio, k , que determina el número de desviaciones estándar que se desea cubrir. Valores elevados de k reducen el riesgo de *stockouts*, aunque incrementan los costes de almacenamiento, mientras que valores bajos producen el efecto contrario. Asimismo, el nivel de servicio constituye una métrica clave para evaluar el rendimiento del sistema de inventario, ya que refleja el porcentaje de la demanda que se logra satisfacer a lo largo de un intervalo de tiempo concreto. [8].

2.1.3. Modelos de series temporales

Las previsiones de la demanda se realizan a partir de un histórico de datos de esta variable. Dado que esta información suele registrarse de forma secuencial a lo largo del tiempo, dichos datos se representan habitualmente como series temporales. Esta estructura consiste de observaciones ordenadas cronológicamente para una variable de interés, y su estudio constituye la base sobre la que se desarrollan numerosos métodos de previsión. En muchos casos, estas observaciones no evolucionan de forma totalmente aleatoria, sino que presentan ciertos patrones sistemáticos que reflejan el comportamiento de la variable a lo largo del tiempo. En este sentido, las series temporales se suelen descomponer con fines analíticos para modelizar su evolución en el tiempo.




Figura 2.2: Descomposición de una serie temporal en sus componentes: serie original (*data*), tendencia general (*trend*), componente estacional (*seasonal*), y residuo (*remainder*) [9].

El primer constituyente es la tendencia general, que hace referencia al comportamiento global de la serie temporal a aumentar o a disminuir durante un largo periodo de tiempo.

Por otro lado, la estacionalidad comprende los movimientos a corto plazo que se observan de manera regular y con periodicidad anual, como aumentos de la demanda durante los periodos navideños. Sin embargo, esta componente se considera que es cíclica si las oscilaciones operan con una periodicidad superior a la anual, como los periodos de prosperidad económica seguidos de las recesiones. Por último, el residuo incluye variaciones erráticas e impredecibles de naturaleza estocástica debido a la falta de variables explicativas [10]. Los distintos componentes mencionados se pueden apreciar en la Figura 2.2, la cual muestra un ejemplo de descomposición de una serie temporal, permitiendo observar cómo cada una de estas unidades contribuye al comportamiento de la serie original.

Una vez identificados los patrones presentes en una serie temporal, el siguiente paso consiste en aplicar métodos capaces de modelar dichas dependencias y generar previsiones futuras. Históricamente, uno de los enfoques más utilizados para este propósito ha sido el empleo de modelos estadísticos tradicionales, diseñados específicamente para capturar la dependencia temporal entre observaciones consecutivas.

Entre los modelos más sencillos destacan los métodos de *Moving Average*, que generan predicciones a partir de combinaciones ponderadas de errores y observaciones pasadas [11]. Posteriormente, surgieron los modelos de *Exponential Smoothing*, los cuales asignan una mayor importancia a las observaciones más recientes y permiten modelar componentes como la tendencia y la estacionalidad [12].

Otro de los enfoques clásicos más utilizados es el de los modelos ARIMA. Estos métodos combinan componentes autorregresivos para modelar la dependencia entre observaciones consecutivas, mecanismos de transformación de la serie temporal, y términos de media móvil para capturar la influencia de errores pasados [13]. Debido a su capacidad para representar dependencias temporales complejas, los modelos ARIMA han constituido históricamente una de las principales referencias en problemas de previsión de series temporales.

2.1.4. Modelos de aprendizaje automático

La evolución de los modelos basados en datos y su aplicación en numerosos ámbitos ha impulsado su uso en problemas de previsión de la demanda. A diferencia de los métodos estadísticos tradicionales, los modelos de aprendizaje automático permiten capturar relaciones no lineales entre variables e incorporar fácilmente información adicional, como promociones, periodos vacacionales o factores comerciales, mejorando así la capacidad predictiva de los sistemas de previsión.

Dentro de este conjunto de técnicas destacan especialmente los modelos basados en árboles de decisión y las arquitecturas de aprendizaje profundo, los cuales han demostrado ofrecer buenos resultados en problemas de previsión de series temporales. A continuación

se describen brevemente algunos de los principales enfoques empleados dentro de estas familias de modelos.

Modelos basados en árboles de decisión

Dentro del campo del aprendizaje automático, los árboles de decisión son uno de los modelos más comunes y estudiados debido a su sencilla interpretación y su alta capacidad explicativa. Su principal objetivo es segmentar el espacio de variables de entrada en regiones disjuntas mediante particiones sucesivas, de forma que las observaciones dentro de cada zona presenten un comportamiento lo más homogéneo posible. Este enfoque permite que estos modelos puedan usarse tanto para tareas de clasificación como de regresión.

El modelo presenta una estructura jerárquica como la de la Figura 2.3, compuesta de un nodo raíz, múltiples nodos internos, y distintos nodos hoja [14]. En problemas de regresión, como el abordado en este trabajo, las particiones se construyen seleccionando en cada nodo la división que minimiza la variabilidad de los valores dentro de las regiones generadas. De este modo, una nueva observación recorre el árbol desde el nodo raíz hasta un nodo hoja, donde se obtiene la predicción final.

Entre sus principales ventajas destacan su capacidad para manejar variables tanto categóricas como continuas, la posibilidad de determinar la importancia de cada variable usada en el modelo, y su fácil interpretación. No obstante, estos modelos también presentan ciertas limitaciones, como una alta sensibilidad a variaciones en los datos de entrada y una cierta tendencia al sobreajuste [15], lo que puede afectar negativamente a su capacidad de generalización.




Figura 2.3: Ejemplo de la estructura de un árbol de decisión para una tarea de regresión, donde los círculos azules representan los nodos hoja, los blancos se corresponden con los nodos internos, y el círculo superior es el nodo raíz [16].

Con el objetivo de mitigar estas limitaciones, surgen los modelos de tipo *ensemble*, que combinan múltiples modelos base con el fin de obtener predicciones más robustas y

precisas. Este enfoque se fundamenta en la idea de que la agregación de varios modelos permite reducir errores individuales y mejorar la capacidad de generalización del sistema [17].

Una de las familias de modelos de tipo *ensemble* más comunes es la de tipo *bagging*, que consiste en generar múltiples subconjuntos de datos a partir del conjunto original mediante muestreo aleatorio con reemplazo, también conocido como *bootstrapping* [18]. En problemas de regresión, para cada subconjunto obtenido se entrena un modelo base, B , de manera que la predicción final, $\hat{f}_{bag}(x)$, se calcula como el promedio de las predicciones de cada modelo base, $\hat{f}^{*b}(x)$, según la Ecuación 4.

$$\hat{f}_{bag}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x) \quad (4)$$

Uno de los modelos más representativos dentro de la familia *bagging* es el algoritmo *Random Forest*, el cual emplea árboles de decisión como modelos base. Este modelo introduce diversidad adicional entre los modelos base, lo que permite mejorar su capacidad de generalización y mejorar una de las principales limitaciones de los árboles de decisión individuales [19].

Otra familia de modelos *ensemble* es la de tipo *boosting*, donde los modelos base se entrenan de forma secuencial. Este planteamiento se fundamenta en la idea de que cada nuevo modelo se entrena para corregir los errores cometidos por los modelos anteriores [20]. En problemas de regresión, este enfoque se formaliza mediante los métodos de *gradient boosting* [21], en los que cada nuevo modelo se entrena para aproximar los errores generados por las predicciones acumuladas hasta ese momento. De este modo, el modelo va refinando progresivamente sus estimaciones a través de un proceso de optimización iterativa de una función de pérdida.

Dentro de esta familia, uno de los algoritmos más destacados es *XGBoost*, que constituye una implementación optimizada de los métodos de *gradient boosting* donde también se utilizan árboles de decisión como modelos base. Este algoritmo introduce múltiples mejoras adicionales y se presenta como un sistema completo de aprendizaje automático, ya que gran parte de su éxito se debe a cómo integra el proceso de entrenamiento con el diseño del sistema [22]. Estos factores han contribuido a que *XGBoost* se haya consolidado como una de las técnicas más utilizadas en problemas de predicción en la actualidad.

Modelos de aprendizaje profundo

En los últimos años, los modelos de aprendizaje profundo han experimentado un notable crecimiento en el ámbito de la previsión de la demanda, impulsados por su capacidad para modelar relaciones complejas y no lineales a partir de grandes volúmenes de datos.

Estos modelos, basados en redes neuronales artificiales, han demostrado un alto rendimiento en entornos caracterizados por una elevada variabilidad y patrones temporales complejos [23].

En este contexto, las RNN, han adquirido un papel relevante para trabajar con datos de naturaleza secuencial, como los textos o las series temporales. A diferencia de otros modelos de aprendizaje profundo donde la información únicamente fluye hacia delante, las RNN están configuradas de tal forma que los datos pueden propagarse hacia capas anteriores [24]. Esto crea un estado interno en la red que permite ajustar la respuesta a una cierta entrada en función de los datos que se han procesado anteriormente. Esto resulta especialmente relevante en problemas de previsión de la demanda ya que permite al modelo capturar dependencias temporales.

El desarrollo continuado de este tipo de redes ha culminado en las arquitecturas LSTM. Estos modelos incorporan una estructura interna basada en un estado de memoria y un estado oculto. Dichos estados representan respectivamente la información almacenada a largo plazo y la salida de la red en cada instante de la secuencia [25]. De esta forma, la red recibe en cada paso tanto la observación actual como la información referente al instante anterior.

Estas redes se estructuran en celdas que presentan la arquitectura de la Figura 2.4, donde el flujo de información dentro de las mismas se regula mediante un conjunto de mecanismos de control [25]. Este diseño permite mantener y actualizar de forma selectiva la información relevante a lo largo del tiempo.




Figura 2.4: Arquitectura de una celda LSTM [17].

De esta forma, las redes LSTM facilitan la propagación de la información a lo largo de secuencias largas [25]. Como resultado, estos modelos pueden capturar dependencias temporales complejas y de largo alcance, lo que los convierte en uno de los modelos de

aprendizaje profundo más empleados en el ámbito de la previsión de la demanda.

2.1.5. Métricas de evaluación del error

La evaluación del rendimiento de los algoritmos de predicción de la demanda constituye un elemento fundamental dentro del proceso de modelización, ya que permite cuantificar la precisión de las predicciones y comparar distintos enfoques de manera objetiva. En este contexto, las métricas de error proporcionan una medida de cuánto difieren las predicciones de los valores reales. Dado que cada métrica captura diferentes aspectos del error cometido, resulta habitual emplear varias de ellas de forma complementaria para obtener una evaluación más completa del comportamiento del modelo. De este modo, a continuación se describen algunas de las métricas más utilizadas en el contexto en el que se enmarca el presente trabajo.

MAE

El MAE es una de las métricas más utilizadas para evaluar la precisión de modelos en tareas de regresión debido a su fácil interpretación. Esta métrica se calcula mediante la Ecuación 5, como el promedio de las diferencias absolutas entre los valores reales, y_i , y las predicciones realizadas por el modelo, $\hat{y}_i$. Además, esta métrica proporciona una medida directa del error medio cometido por el modelo en las mismas unidades que la variable objetivo, lo que facilita su interpretación en términos prácticos. Por otro lado, al no elevar los errores al cuadrado, el MAE no penaliza de forma excesiva los errores grandes, lo que lo hace más robusto frente a valores extremos en comparación con otras métricas. Sin embargo, este indicador no es apropiado para comparar series temporales con diferentes escalas, ya que su valor depende directamente de la magnitud de la variable analizada [26].

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5)$$

RMSE

El RMSE es otra de las métricas más utilizadas en la evaluación de modelos de regresión. A diferencia del MAE, esta métrica eleva al cuadrado los errores antes de sumarlos y promediarlos, dando lugar al MSE. Posteriormente aplica la raíz cuadrada para tener las mismas unidades que la variable objetivo, tal y como se expresa en la Ecuación 6.

El RMSE penaliza en mayor medida los errores de gran magnitud debido al término cuadrático, lo que lo hace especialmente sensible a valores atípicos. Este hecho resulta útil

en aquellos contextos donde los errores grandes tienen un impacto significativo y deben ser evitados. Asimismo, al igual que el MAE, el RMSE también presenta limitaciones al comparar series temporales en una escala distinta dado que también se basa en una medida del error absoluto [26].

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (6)$$

RMSSE

El RMSSE es un indicador que evalúa el rendimiento del modelo de previsión en relación a un modelo ingenuo de referencia basado en la demanda observada en el periodo anterior. De este modo, permite interpretar si las predicciones obtenidas suponen una mejora respecto a una estrategia básica que utiliza como predicción el último valor observado. Su cálculo se efectúa mediante la Ecuación 7, donde el numerador corresponde al MSE del modelo evaluado sobre el horizonte de predicción, h , mientras que el denominador representa el MSE del modelo ingenuo calculado a partir de los datos históricos del conjunto de entrenamiento. Nótese que este último término permite normalizar el error del modelo en función de la variabilidad histórica de la serie temporal al calcularse sobre el conjunto de aprendizaje. [27].

$$RMSSE = \sqrt{\frac{\frac{1}{h} \sum_{i=n+1}^{n+h} (y_i - \hat{y}_i)^2}{\frac{1}{n-1} \sum_{i=2}^n (y_i - y_{i-1})^2}} \quad (7)$$

La principal ventaja del RMSSE es que elimina el efecto de la escala de los datos normalizando las series respecto a la variabilidad histórica de cada producto. Esta característica resulta especialmente relevante en entornos de gestión de inventarios, donde es habitual trabajar con múltiples productos con comportamientos de demanda heterogéneos.

2.2 Estado del arte

Con el objetivo de que el presente trabajo aporte una contribución relevante dentro del ámbito de la previsión de la demanda, resulta necesario realizar una revisión de la literatura científica sobre esta problemática. Para ello, conviene analizar diversas publicaciones académicas que abordan el uso de métodos estadísticos y modelos de aprendizaje automático aplicados a la previsión de la demanda y a la gestión de inventarios. Este análisis permite identificar las metodologías más utilizadas, así como las principales limitaciones y oportunidades de investigación en este campo.

2.2.1. Descripción de publicaciones relacionadas con la temática

El interés en el desarrollo de modelos de previsión de la demanda ha aumentado en las últimas décadas con los avances en los campos del aprendizaje automático y del aprendizaje profundo. Este hecho se puede apreciar en términos de artículos científicos publicados en la década del 2010, donde se observa un crecimiento progresivo en el volumen de publicaciones en el ámbito, tal y como ilustra la Figura 2.5. Este fenómeno se debe a que los métodos basados en datos permiten a las empresas procesar grandes volúmenes de información histórica y en tiempo real, identificando patrones complejos y relaciones no lineales entre las variables.

Los trabajos pioneros en la aplicación de técnicas de aprendizaje automático a esta problemática se publicaron a mitad de la década de los 2000. Sus objetivos principales consistían en la comparación de métodos estadísticos tradicionales de series temporales con redes neuronales artificiales y máquinas de soporte vectorial para la previsión de la demanda en cadenas de suministro [28], [29]. Como una de las primeras implementaciones de modelos de aprendizaje automático en este contexto, estos estudios concluyeron que generalmente estos modelos no producían resultados significativamente mejores que los modelos estadísticos tradicionales. Esto puede atribuirse tanto al limitado desarrollo de estas técnicas como a la menor disponibilidad de datos y capacidad computacional en aquella etapa inicial.



Figura 2.5: Número de publicaciones científicas en el ámbito de la previsión de la demanda en la década del 2010 [30].

Con el paso del tiempo, la literatura ha ampliado este tipo de análisis comparativos incorporando conjuntos de datos más extensos y una mayor variedad de métodos de previsión. En este sentido, trabajos posteriores han abordado comparaciones entre modelos estadísticos clásicos y diferentes algoritmos de aprendizaje automático aplicados a la previsión de la demanda a nivel de producto. Los resultados de estos estudios sirven para demostrar que los modelos de aprendizaje automático pueden mostrar mejoras en preci-

sión frente a los enfoques tradicionales, particularmente cuando se dispone de conjuntos de datos más voluminosos y heterogéneos [31].

Más recientemente, el desarrollo de arquitecturas de aprendizaje profundo ha abierto nuevas posibilidades para el modelado de series temporales de demanda. En particular, algunos trabajos han explorado modelos híbridos de redes neuronales con el objetivo de capturar tanto patrones locales como dependencias temporales a larga distancia en la demanda. En esta línea, se han propuesto arquitecturas basadas en la combinación de redes neuronales convolucionales y redes LSTM bidireccionales para la previsión de la demanda de productos en entornos minoristas. Este enfoque demostró mejoras en precisión frente a distintos modelos de aprendizaje automático tradicionales, como kNN o *Random Forest*, y métodos estadísticos de series temporales [32]. Estos resultados sugerían que las técnicas de aprendizaje profundo podían ofrecer ventajas adicionales cuando se disponía de volúmenes de datos suficientes y de estructuras temporales complejas.

Más allá de los trabajos centrados en la comparación entre modelos estadísticos y técnicas de aprendizaje automático, una parte relevante de la literatura reciente se ha orientado hacia la aplicación de estos métodos en entornos comerciales reales. Esto se ha logrado incorporando variables explicativas adicionales que ofrecen un contexto fundamental para comprender ciertas variaciones imprevistas de la demanda. Distintos trabajos han mostrado que modelos como *XGBoost* permiten capturar relaciones complejas entre las variables explicativas y la demanda. Esto es posible cuando los conjuntos de datos se enriquecen con atributos relacionados con factores temporales y comerciales. Por ejemplo, variables referentes a periodos promocionales, características de los establecimientos, o el número de clientes, tal y como muestra la Figura 2.6 [33].

A	B	C	D	E	F	G
Store	DayOfWeek	Date	Sales	Customer	Open	Promo
1	5	7/31/2015	5263	555	1	1
2	5	7/31/2015	6064	625	1	1
3	5	7/31/2015	8314	821	1	1
4	5	7/31/2015	13995	1498	1	1
5	5	7/31/2015	4822	559	1	1
6	5	7/31/2015	5651	589	1	1
7	5	7/31/2015	15344	1414	1	1
8	5	7/31/2015	8492	833	1	1
9	5	7/31/2015	8565	687	1	1

Figura 2.6: Ejemplo del enriquecimiento de un conjunto de datos para la previsión de la demanda con variables exógenas [33].

Asimismo, la incorporación de variables externas de carácter macroeconómico o empresarial también ha demostrado ser una buena estrategia para mejorar la capacidad

predictiva de los modelos. Estos campos reflejan de forma más completa el contexto en el que se genera la demanda. Entre estos atributos se incluyen indicadores económicos, información sobre ventas históricas, niveles de inventario o variables relacionadas con el entorno competitivo de la empresa [34].

Otro reto relevante en la literatura es el modelado de series caracterizadas por patrones de demanda intermitente, que es una situación frecuente en el caso de repuestos o las denominadas *spare parts*. Estas situaciones dificultan la aplicación directa de muchos modelos tradicionales, ya que suelen implicar largos periodos sin ventas con picos esporádicos de demanda. Esto ha propiciado el desarrollo de enfoques específicos para estos casos de estudio. En este contexto, diversas líneas de investigación han analizado el uso de métodos de regresión y técnicas de aprendizaje automático para abordar este tipo de series irregulares [35]. Adicionalmente, también se han explorado estrategias basadas en aprendizaje por conjuntos y modelos híbridos orientados a mejorar la robustez de las predicciones en entornos industriales [36], [37]. Más recientemente, también se ha abordado el problema desde una perspectiva probabilística, proponiendo modelos capaces de estimar no solo un valor puntual de la demanda futura sino también su distribución. Este enfoque resulta especialmente útil para incorporar la incertidumbre del pronóstico en las decisiones de gestión de inventario [38].




Figura 2.7: Arquitectura de una herramienta de decisión para la gestión de inventarios dinámicos [34].

Una parte creciente de la investigación científica en este ámbito se ha centrado en la integración de estos modelos dentro de los procesos de gestión de inventario. En este sentido, la combinación de modelos de previsión de la demanda con herramientas de apoyo a la toma de decisiones permite evaluar el impacto de las predicciones en las variables

operativas. Algunos de estos factores son los niveles de servicio, el dimensionamiento del inventario o los costes asociados a roturas de *stock*. Desde esta perspectiva, algunos trabajos han desarrollado sistemas de soporte a la decisión que integran modelos de aprendizaje automático junto con métodos de series temporales. El aporte diferencial recae en la implementación de técnicas de optimización para decidir si la mejor decisión empresarial es comprar, vender, o mantener el *stock*. Esto se logra empleando la arquitectura de la Figura 2.7, donde se utilizan variables como el precio del inventario en el mercado, el coste de mantenimiento del *stock*, el inventario de seguridad, y el nivel de existencias actuales, además de las predicciones de la demanda [34].

De forma similar, otro enfoque usual en la literatura consiste en utilizar métricas de rendimiento que consideren el impacto en términos de coste de inventario. Dicha métrica incorpora simultáneamente el coste asociado a las roturas de *stock* y al exceso de inventario. Esto permite seleccionar modelos de previsión que no solo minimicen el error estadístico sino que también optimicen el rendimiento operativo del sistema de inventario [39]. El procedimiento supone un planteamiento totalmente distinto respecto a los estudios previos. Además, sirve para reforzar la idea que por mucho que se obtengan métricas de evaluación del rendimiento de los modelos aceptables, esto no necesariamente se traduce en costes de inventario bajos.

Otros autores han apostado por un enfoque novedoso donde el propio modelo aprende cuál es la mejor política de reposición en todo momento a partir de la interacción con el estado del sistema de inventario. Esto es posible gracias al aprendizaje profundo por refuerzo, donde el problema se formula como un proceso de decisión secuencial en el que las decisiones de reposición se toman de forma repetida a lo largo del tiempo. A diferencia de los enfoques tradicionales, que separan la previsión de la demanda y la optimización de inventario en etapas independientes, estos métodos integran ambas tareas dentro del propio entrenamiento. De este modo, es posible emplear información del estado del sistema, como el nivel de inventario, los pedidos pendientes, o las predicciones de demanda, para determinar la cantidad óptima a reponer en cada periodo, optimizando directamente el coste total del proceso [40].

2.2.2. Tabla resumen

Con el objetivo de sintetizar la información más relevante de las publicaciones analizadas, se presenta en la Tabla 2 un resumen comparativo de los principales trabajos revisados en la literatura. Este resumen permite identificar de forma estructurada las tendencias existentes en el ámbito de la previsión de la demanda, como el uso predominante de datos históricos junto con variables exógenas, o la aplicación recurrente de modelos de aprendizaje automático y técnicas de *ensemble*.

Tabla 2: Contribuciones científicas al campo de la previsión de la demanda.

Artículo	Variables	Sector	Algoritmos de ML	Métricas de error
Carboneau et al. [28], [29]	Demanda histórica	Producción de chocolate y cartuchos de tinta	MLR, SVR, RNN	NMAE
Spiliotis et al. [31]	Demanda histórica	Comercio minorista	MLP, BNN, <i>Random Forest</i> , kNNR, SVR	RMSSE, AMSE
Joseph et al. [32]	Ventas, fechas, identificadores de las tiendas y productos	Tiendas físicas	CNN-BiLSTM, LR, kNNR, SVR, <i>XGBoost</i>	R^2 , MAE, MAPE
Ramya et al. [33]	Ventas, fechas, identificadores de las tiendas, promociones, festividades, datos de la competencia	Droguerías	<i>XGBoost</i>	RMSPE
Namir et al. [34]	Demanda histórica, histórico de precios, precios actuales	Lubricantes de maquinaria pesada	<i>XGBoost</i>	Precisión
Ifraz et al. [35]	Ventas, total de vehículos, mantenimiento periódico, número de fallos, tiempo promedio entre fallos	Flota de autobuses	MLR, SVR, <i>Random Forest</i> , ANN	MAPE
Chien et al. [36]	Producción de piezas de automóviles	Producción de piezas de automóviles	<i>Stacking (XGBoost, LR)</i>	MAE, SMAPE
Affonso et al. [37]	Demanda mensual, periodos de demanda, periodos sin demanda, <i>lead time</i>	Extracción de menas de hierro	Modelos estadísticos tradicionales	MAE, MSE

Wang et al. [38]	Ventas, productos, departamentos, tiendas, fechas, precios	Tiendas <i>Walmart</i>	<i>LightGBM</i> , LSTM	Puntuación de <i>Brier</i> , logarítmica y DRPS
Tadayonrad et al. [39]	Demanda histórica, estacionalidad, fiabilidad del suministro	Cadena de suministro	LSTM	MAE
Dehaybe et al. [40]	Demanda histórica, inventario, costes	Optimización de inventario	DRL	<i>Median gap</i>
El trabajo presente	Demanda histórica, promociones, aperturas, festividades, precios, ciclos de reposición	Productos para el automóvil	<i>Random Forest</i> , <i>XG-Boost</i> , LSTM	RMSE, RMSSE

Asimismo, también se ha incluido el enfoque adoptado en el presente trabajo.

2.2.3. Conclusiones del estado del arte

Parte de la literatura reciente en el ámbito de la previsión de la demanda muestra un creciente interés por integrar los modelos predictivos con la toma de decisiones operativas en la gestión de inventarios. Sin embargo, gran parte de los estudios continúan centrados principalmente en la mejora de la precisión estadística de los modelos, mientras que el análisis de su impacto económico y operativo en sistemas reales de inventario ha recibido una atención relativamente menor.

En este contexto, el presente trabajo propone un enfoque basado en datos que combina distintos modelos de previsión de la demanda con una política de gestión de inventario. Con este fin, se han seleccionado modelos representativos de diferentes enfoques metodológicos ampliamente utilizados en la literatura, como algoritmos *ensemble* como *Random Forest* y *XGBoost*, y una red neuronal LSTM. Todos estos modelos han demostrado ofrecer buenos resultados en problemas de previsión de la demanda con relaciones no lineales.

Asimismo, se ha decidido evaluar el rendimiento de estos modelos con el RMSE y el RMSSE, ya que permiten capturar distintos aspectos relevantes del problema. El RMSE penaliza de forma más intensa los errores grandes, lo que resulta especialmente adecuado en el contexto de la gestión de inventarios. En este contexto, una subestimación significativa de la demanda puede derivar en roturas de *stock* y pérdidas económicas importantes. Por otro lado, el RMSSE es una métrica de error normalizada, hecho que permite comparar los rendimientos de los distintos algoritmos. Esto resulta especialmente relevante, ya que en algunos casos se han empleado distintos conjuntos de productos con diferentes niveles de demanda y patrones de comportamiento. De este modo, el uso conjunto de ambas métricas proporciona una evaluación más completa, combinando la sensibilidad a errores críticos con la capacidad de comparación entre series heterogéneas.

3 Diseño e implementación del trabajo

3.1 Origen de los datos

El proyecto se ha desarrollado a partir de una serie de conjuntos de datos de un punto de venta de una empresa de productos del automóvil. En este contexto, se ha trabajado con datos de 1.000 productos de esta compañía, los cuales se encuentran anonimizados por motivos de confidencialidad para un uso estrictamente académico. Los datos incluyen variables explicativas relacionadas tanto con los propios artículos como con la dinámica operativa de la empresa. Estos atributos proveen a los modelos de aprendizaje automático el contexto necesario para entender los patrones cambiantes de la demanda de cada producto.

3.1.1. Obtención

Los datos con los que se ha tratado a lo largo del proyecto han sido obtenidos por medio de la tutora del presente trabajo a través del correo electrónico. La información se ha obtenido en formato digital a través de esta misma vía de comunicación sin necesidad de realizar ningún proceso de recopilación directa.

3.1.2. Descripción

La información relevante para el desarrollo de la parte práctica del trabajo se organiza en tres ficheros de extensión *xlsx*, donde cada uno contiene diversos datos de los productos relacionados con algún ámbito empresarial concreto. Asimismo, algunos de estos archivos se organizan a su vez en múltiples hojas, por lo que seguidamente se listan todos estos elementos y se detalla el contenido de cada uno de ellos.

1. *DatosCicloAprovisionamiento.xlsx* → Contiene los campos *producto*, referente al identificador de cada ítem, *diasEntrePedidos*, siendo los días del ciclo de revisión de cada artículo, y *diasLeadTime*, que es el tiempo de entrega de cada ítem.
2. *DatosPrecioMedio.xlsx* → Incluye los datos referentes a los precios de cada artículo. Contiene los atributos *producto* y *eurPrecioMedio*, que es el precio medio de cada producto.
3. *Datos.xlsx* → Este es el fichero principal de datos, y está compuesto por cuatro hojas distintas que se listan seguidamente.
 - Hoja *Venta* → Presenta la información de la demanda de cada producto. Incluye las variables *producto*, *idSecuencia*, que codifica las fechas en formato

YYYYmmdd, y la variable objetivo *udsVenta*, que representa las ventas de un producto en un día concreto.

- Hoja *Calendario* → Contiene los datos referentes a las fechas del calendario. Incluye los atributos *idSecuencia*, *bolOpen*, que indica si la tienda se encontraba abierta en un día concreto, y *bolHoliday*, que denota si la fecha se corresponde a una festividad.
- Hoja *Promociones* → Incluye los datos de los periodos promocionales a los que está sujeto cada artículo. Incluye los campos *producto*, *idSecuenciaIni*, que codifica la fecha inicial de la promoción, e *idSecuenciaFin*, que representa la fecha del fin del periodo promocional. Esta hoja incluye todas las combinaciones de productos y periodos de oferta a los que se han visto sujetos.
- Hoja *Stock* → Contiene el histórico del inventario disponible de cada producto. Contiene las variables *producto*, *idSecuencia*, y *udsStock*, referente a las unidades de un artículo en una fecha concreta.

3.1.3. Carga

Para facilitar la realización de todas las etapas del proyecto, se han unido los tres archivos anteriormente mencionados en un solo conjunto de datos. Este proceso de integración se ha realizado respecto a la hoja *Venta* del archivo *Datos.xlsx*, a la que se han unido los otros ficheros y hojas mediante operaciones del tipo **LEFT JOIN** de SQL. De esta forma se tiene constancia de las ventas de cada producto en todo momento.

Las uniones entre los distintos archivos y hojas se han llevado a cabo empleando como claves de integración bien el atributo *producto* o bien la variable *idSecuencia*, en función de la naturaleza de la información contenida en cada fichero. En términos generales, el atributo *producto* permite vincular la información específica de cada artículo, mientras que *idSecuencia* actúa como identificador temporal. No obstante, la fusión con la hoja *Promociones* de *Datos.xlsx* no es trivial, porque contiene las fechas de inicio y finalización de los periodos promocionales de todos los artículos. Para ello, se ha utilizado la correspondencia entre el identificador del producto y el intervalo temporal definido en la hoja *promociones*, delimitado por los campos que indican el inicio y el fin de cada campaña. A partir de esta relación, se ha construido la variable *isPromo*. Este campo indica para cada producto y fecha si las ventas se han producido durante un periodo promocional.

3.2 Exploración de los datos

En esta fase del proyecto se han realizado aquellas tareas que permiten familiarizarse tanto con la estructura del *dataset* como con las distintas variables que lo componen.

Tabla 3: Resumen del contenido del conjunto de datos integrado.

Variable	Tipo	Rol	Origen	Descripción
<i>producto</i>	Catórica	Predictiva	Hoja <i>Venta de Datos.xlsx</i>	Identificador único de cada producto
<i>idSecuencia</i>	Temporal	Predictiva	Hoja <i>Venta de Datos.xlsx</i>	Código de una fecha en formato <i>YYYYmmdd</i>
<i>udsVenta</i>	Entero	Objetivo	Hoja <i>Venta de Datos.xlsx</i>	Número de unidades vendidas de un artículo en un día concreto
<i>isPromo</i>	Binaria	Predictiva	Hoja <i>Promociones de Datos.xlsx</i>	Indica si el ítem estaba en promoción en una fecha determinada
<i>bolOpen</i>	Binaria	Predictiva	Hoja <i>Calendario de Datos.xlsx</i>	Indica si la tienda estaba abierta un día concreto
<i>bolHoliday</i>	Binaria	Predictiva	Hoja <i>Calendario de Datos.xlsx</i>	Indica si es día festivo
<i>udsStock</i>	Entero	Predictiva	Hoja <i>Stock de Datos.xlsx</i>	Número de unidades disponibles de un producto en una fecha concreta
<i>diasEntrePedidos</i>	Entero	Predictiva	<i>DatosCicloAprovisionamiento.xlsx</i>	Intervalo de tiempo de revisión de los niveles de inventario de un ítem en días
<i>diasLeadtime</i>	Entero	Predictiva	<i>DatosCicloAprovisionamiento.xlsx</i>	Tiempo de entrega de los pedidos por parte de los proveedores en días
<i>eurPrecioMedio</i>	Decimal	Predictiva	<i>DatosPrecioMedio.xlsx</i>	Precio medio del ítem

3.2.1. Resumen

La Tabla 3 permite entender la naturaleza de los campos que componen el conjunto de datos tras el proceso de integración, así como el concepto que representan.

Este *dataset* presenta un total de 629.391 registros sin duplicados. Cada muestra corresponde a una observación diaria de un producto concreto, lo que da lugar a un problema de naturaleza multiserie temporal. Cada serie representa la evolución de la demanda de un producto a lo largo del tiempo, con una frecuencia diaria y un horizonte temporal que abarca desde marzo de 2024 hasta marzo de 2026.

En este sentido, el juego de datos puede interpretarse como un conjunto de múltiples series temporales paralelas, donde cada observación viene determinada por la combinación de los atributos *producto* e *idSecuencia*. Asimismo, para predecir el comportamiento de la variable objetivo *udsVenta*, se han incorporado diversas variables explicativas relacionadas con el calendario, las promociones, el inventario y las características logísticas de cada producto. La naturaleza de estos campos es muy variada, incluyendo atributos categóricos, numéricos y binarios. Esto permite capturar tanto patrones temporales como efectos externos que influyen en la demanda. Por último, la variable *idSecuencia* se ha empleado en la generación de múltiples gráficos donde se referencia con el nombre *fecha* para facilitar su interpretación.

3.2.2. Análisis de la calidad de los datos

Antes de realizar cualquier análisis estadístico detallado, resulta fundamental evaluar la calidad del conjunto de datos con el objetivo de garantizar la fiabilidad de los resultados posteriores. Este análisis permite identificar posibles problemas como valores nulos, inconsistencias o anomalías en las variables. De este modo, se asegura que el conjunto de datos utilizado en las siguientes etapas del trabajo sea coherente, completo y adecuado para su explotación.

Análisis de rangos

Uno de los indicadores más simples e informativos de la calidad de los datos son los rangos numéricos que estos abarcan. Estos intervalos deben comprender un conjunto de valores coherente con la naturaleza de cada variable. Por ejemplo, resultaría ilógico encontrar valores negativos en variables cuya interpretación no lo permite. Para realizar este análisis, se ha optado por la visualización de los histogramas de todos los atributos y la generación de *boxplots* para las variables numéricas. Además, en el caso de aquellas variables cuya distribución presenta una elevada asimetría, se ha decidido representarlas en escala logarítmica. En el caso de las variables binarias, se ha preferido representar el total de cada una de sus clases para facilitar el análisis.




Figura 3.1: Distribuciones de las variables.

Las distribuciones representadas en la Figura 3.1 permiten comprobar que las variables numéricas del conjunto de datos presentan valores coherentes con su interpretación, sin evidencias de errores como valores negativos o incongruentes. No obstante, de acuerdo con los *boxplots* de la Figura 3.2, en algunas de estas variables se observan valores extremos, especialmente en el caso de *udsStock*, *udsVenta* y *eurPrecioMedio*. Estos valores no se consideran errores, ya que reflejan comportamientos reales del negocio, como picos de demanda en determinados productos o artículos con precios significativamente más elevados que la media. Por este motivo, no se ha contemplado la posibilidad de aplicar ningún tratamiento específico sobre estos valores, ya que su eliminación puede suponer la pérdida de información relevante para el entrenamiento de los modelos de predicción.

Por otro lado, las proporciones de las dos categorías de las variables binarias *isPromo*, *bolOpen* y *bolHoliday* son coherentes con la naturaleza de los propios atributos. En este caso, en la mayoría de los días del *dataset* los artículos no se han sometido a una promoción, gran parte de las fechas no se corresponden con días festivos, y el establecimiento ha abierto sus puertas durante la mayor parte de los días del conjunto de datos.




Figura 3.2: *Boxplots* de las variables numéricas.

Finalmente, la distribución de horizontes de la demanda es muy uniforme. Teniendo en

cuenta que las ventas se ofrecen a nivel de día-producto, esto indica que los intervalos de las series temporales de la demanda de cada ítem son uniformes. Asimismo, este periodo abarca dos años, desde marzo del 2024 hasta el mismo mes del año 2026. No obstante, esto entra en conflicto con lo observado en el histograma de la variable *producto*, donde la distribución de las apariciones de los distintos artículos en el conjunto de datos no es homogénea. Dado que el conjunto de datos integrado no presenta valores duplicados, esto demuestra que el *dataset* no contiene la información de todos los 1.000 productos. Esto se debe a que la hoja *Venta* del archivo *Datos.xlsx* no contiene los históricos de la demanda de todos los artículos, de forma que solo se dispone de los datos de los ítems de esta hoja al haber realizado una operación de tipo **LEFT JOIN** durante el proceso de integración. Este hecho no ha supuesto un impedimento en cuanto a la dinámica del desarrollo del proyecto, ya que simplemente se debe tener en consideración a la hora de interpretar algunos de los resultados.

Análisis de incoherencias

Otro aspecto relevante que se ha tenido en cuenta durante el análisis de la calidad de los datos es la presencia de incoherencias derivadas de la relación entre algunas variables. En particular, se han detectado 1.621 muestras donde el número de unidades vendidas en una fecha concreta supera el *stock* disponible para ese mismo producto y día.




Figura 3.3: Demanda y *stock* disponible de varios productos.

Este comportamiento puede deberse a diferentes causas, como desfases temporales en el registro del inventario o inconsistencias en la medición del *stock* disponible. No obstante, dado que las ventas representan transacciones reales registradas en el sistema, se ha considerado que es más plausible que la fuente de estas incoherencias resida en la variable *udsStock* en lugar de en *udsVenta*. Esta hipótesis se ve reforzada al analizar conjuntamente

la evolución temporal de las ventas y del inventario para distintos productos. Tal y como se puede apreciar en la Figura 3.3, en determinados puntos del histórico se observan caídas abruptas del nivel de *stock*, seguidas de incrementos igualmente bruscos que no guardan relación con el comportamiento de la demanda. Este tipo de patrón resulta difícil de justificar si se asume una correcta sincronización entre ventas y niveles de inventario, lo que sugiere la existencia de desajustes en el registro del *stock*.

Análisis de inconsistencias temporales

Durante el análisis exploratorio de los datos se han detectado un seguido de inconsistencias temporales respecto a las variables *bolOpen* y *bolHoliday*.




Figura 3.4: Calendario operativo de la empresa de productos automovilísticos a lo largo de todo el horizonte temporal de sus productos. Los recuadros rojos referencian los domingos, los cuadrados morados se corresponden con los días que la empresa reconoce como festivos, las casillas blancas indican que el establecimiento no abrió sus puertas, y las cuadrículas negras se corresponden con las fechas en las que la tienda sí abrió.

Como se observa en la Figura 3.4, a partir de la segunda mitad del histórico de la demanda desaparecen los registros asociados a los días festivos y a las aperturas del punto de venta. Esto resulta totalmente ilógico desde un punto de vista operativo, y contrasta con la primera mitad de la serie donde ambos atributos presentan una estructura coherente y regular. Además, esta observación sugiere una pérdida de información en estas variables para los periodos más recientes. Este fenómeno indica que dichas variables no han sido correctamente registradas o actualizadas en el tramo final del histórico, por lo que su uso directo podría introducir ruido o sesgo en los modelos.

Análisis de los valores nulos

Uno de los aspectos más importantes que se ha considerado durante la exploración de los datos es la presencia de valores nulos. En este contexto, estos valores aparecen durante el proceso de integración de los datos en aquellas variables cuya información no está disponible para todas las combinaciones de *producto* e *idSecuencia*.

Dicho esto, se ha observado la presencia de valores ausentes en las variables *bolOpen*, *bolHoliday* y *udsStock*. Estos valores se concentran exclusivamente en la primera observación de todas las series temporales y se deben a la falta de información disponible para dichas fechas en los archivos originales. Esto indica que las fuentes de los datos no cubren completamente el intervalo temporal considerado en el conjunto de la hoja *Venta* del archivo *Datos.xlsx*. Por lo tanto, en este caso la presencia de los valores ausentes simplemente se debe a un desajuste temporal entre las distintas fuentes de información.

Análisis de las roturas de stock

Los *stockouts* son un fenómeno que se produce cuando no se dispone de suficiente *stock* para satisfacer la demanda de un artículo. En estas situaciones la demanda se ve censurada y los datos no reflejan la realidad de esta variable. De no tenerse en cuenta estos sucesos, los modelos de *machine learning* podrían interpretar estas situaciones como periodos de baja demanda, cuando en realidad corresponden a restricciones de oferta. Esto podría inducir a los modelos a aprender patrones incorrectos, infravalorando la demanda en determinados contextos y deteriorando su capacidad predictiva.




Figura 3.5: *Boxplot* de la fracción de roturas de *stock* totales en cada producto.

Como se observa en la Figura 3.5, la proporción total de periodos con *stockouts* suele ser muy baja para la gran mayoría de productos del *dataset*. Únicamente un reducido subconjunto de artículos presenta más de un 10 % de roturas de inventario respecto al total de su histórico de la demanda.

3.2.3. Análisis estadístico

Una vez se ha analizado la calidad del conjunto de datos, se ha procedido con un breve análisis estadístico descriptivo de las variables numéricas del *dataset*.

Tabla 4: Estadísticos descriptivos de las variables numéricas.

	Total	Media	Desv.	Mín.	25 %	50 %	75 %	Máx.
<i>udsVenta</i>	629391	1.19	2.22	0	0	0	2	397
<i>udsStock</i>	629391	44.59	33.59	0	27	39	55	717
<i>eurPrecioMedio</i>	629391	50.60	67.86	0.01	8.57	26.71	62.92	625.26
<i>diasLeadtime</i>	629391	5.48	5.25	1	2	4	4	22
<i>diasEntrePedidos</i>	629391	13.73	2.52	1	14	14	14	34

A partir de los estadísticos recogidos en la Tabla 4 de las variables numéricas, se han extraído varias conclusiones relevantes. En primer lugar, las variables *udsVenta* y *udsStock* presentan una distribución altamente asimétrica, tal y como se observa por la diferencia entre las medias y las medianas, así como por la presencia de valores máximos muy elevados. Esto indica que la demanda se caracteriza por una gran cantidad de días con ventas nulas o muy bajas combinados con picos puntuales de alta demanda. En cuanto a la variable *eurPrecioMedio*, se observa una elevada dispersión, lo que refleja una considerable heterogeneidad en el catálogo de productos. Por otro lado, las variables *diasLeadtime* y *diasEntrePedidos* presentan una variabilidad más contenida, lo que sugiere una mayor estabilidad en los procesos logísticos. En particular, *diasEntrePedidos* muestra una concentración clara alrededor de 14 días, indicando un patrón de reposición bastante regular para la mayoría de productos.

3.3 Preparación de los datos

El siguiente paso en la implementación del presente trabajo ha consistido en la aplicación de técnicas orientadas a adecuar la información para el entrenamiento de los modelos de *machine learning*.

3.3.1. Limpieza

A partir de los problemas que se han identificado durante el análisis de la calidad de los datos, se han tomado una serie de medidas para garantizar la coherencia de la información del *dataset*.

Tratamiento de las incoherencias

Tras haber situado el origen de las 1.621 muestras del conjunto de datos donde el número de ventas supera el inventario disponible en la variable *udsStock*, se ha decidido no aplicar ningún tratamiento específico sobre estos registros. La razón se debe a que el nivel de inventario no se ha terminado utilizando como variable explicativa en los modelos de aprendizaje automático, y su uso ha quedado limitado al análisis de las roturas de *stock*. Como consecuencia, no se ha considerado necesaria la aplicación de ningún proceso de limpieza a este campo. Esta decisión se debe a que *udsStock* no es un atributo exógeno, sino que está condicionado tanto por la propia dinámica de ventas como por las decisiones operativas de reposición. Por lo tanto, su inclusión en el entrenamiento de los modelos de *machine learning* podría inducir a los algoritmos a aprender relaciones derivadas de restricciones de inventario, en lugar de capturar el comportamiento real de la demanda.

Tratamiento de las inconsistencias temporales

Para asegurar la calidad de las variables *bolOpen* y *bolHoliday*, se ha optado por su reconstrucción manual a partir de los datos disponibles entre marzo de 2024 y marzo de 2025. En este sentido, se ha considerado que los patrones de festividades y aperturas observados durante dicho intervalo se repiten en los años posteriores.




Figura 3.6: Calendario reconstruido de la compañía.

A partir de la información disponible, se han asignado de forma sistemática los valores de *bolHoliday* y *bolOpen* a lo largo de todo el histórico de la demanda de las series del conjunto de datos, replicando el patrón identificado en el periodo inicial. Asimismo, también se ha tenido en cuenta que la empresa considera todos los domingos como días festivos y

que el establecimiento permanece cerrado dichos días, exceptuando el último domingo de junio. De este modo, se garantiza la coherencia temporal de estas variables y se evita la introducción de valores faltantes e inconsistencias que puedan afectar al rendimiento de los modelos de predicción. Por otro lado, el detalle completo de las festividades identificadas y del calendario utilizado para reconstruir ambas variables se ha incluido como información adicional en el apartado A.2 del anexo del trabajo. El resultado final de este proceso puede observarse en la Figura 3.6. Cabe recordar que los recuadros rojos referencian los domingos, los cuadrados morados se corresponden con los días que la empresa reconoce como festivos, las casillas blancas indican que el establecimiento no abrió sus puertas, y las cuadrículas negras se corresponden con las fechas en las que la tienda sí abrió.

Tratamiento de los valores nulos

Después de haber identificado que todos los valores nulos del conjunto de datos se sitúan en el inicio de todas las series temporales, se ha optado por eliminar todos los registros con estos valores. Se considera que el impacto negativo que supone esta acción es mínimo. Únicamente se ha eliminado una fecha por producto y los intervalos de la demanda histórica de cada artículo abarcan alrededor de dos años.

Tratamiento de las roturas de *stock*

Tras haber analizado la distribución de los porcentajes de *stockouts* respecto al total de ventas de los históricos de la demanda de cada artículo, se ha decidido realizar un proceso de imputación de los valores de la variable *udsVenta* asociados a *stockouts*.




Figura 3.7: Variable *udsVenta* antes y después del proceso de interpolación lineal de varios productos.

Para facilitar este proceso, se ha decidido descartar del conjunto de datos aquellos

productos cuyo porcentaje de roturas de *stock* supera el 10%, dado que únicamente representan aproximadamente un 4% del total de artículos. Esta decisión se fundamenta en que, en estos casos, la imputación de la variable objetivo implicaría reconstruir una parte significativa de la serie temporal, lo que podría introducir un sesgo considerable y distorsionar los patrones reales de la demanda. Por el contrario, para los productos con una baja proporción de roturas, la imputación afecta únicamente a una fracción reducida de las observaciones, por lo que el impacto sobre la distribución de la variable objetivo es limitado. Asimismo, establecer un umbral inferior al 10% se considera excesivamente restrictivo, ya que conllevaría la eliminación de un número elevado de productos, hecho que implicaría una pérdida relevante de información en el conjunto de datos.

El proceso de imputación que se ha empleado es una interpolación lineal de *udsVenta*. De esta forma se estiman las roturas de inventario a partir de la información local de la serie, preservando su estructura temporal. Además, esta metodología proporciona una aproximación razonable de la demanda sin introducir una complejidad innecesaria ni supuestos difíciles de justificar. La Figura 3.7 ilustra los resultados de este procedimiento en un par de productos. Como se observa, la imputación ha permitido reconstruir la demanda de forma coherente respetando la dinámica de la serie en intervalos de duración breve.

Por otro lado, también se han considerado aquellas series donde los primeros registros de la demanda histórica se corresponden con una rotura de inventario. En estos casos no es posible realizar una imputación basada en interpolación, ya que no se dispone de información previa sobre la que apoyarse. Tal y como se observa en la Figura 3.8, la proporción de estos casos es reducida, alcanzando como máximo alrededor del 5% de la longitud de las series temporales.




Figura 3.8: *Boxplot* de la fracción de roturas de *stock* iniciales para cada producto.

Como consecuencia, se ha optado por la eliminación de estos registros iniciales asumiendo una pérdida de información despreciable en el conjunto de datos. Esta decisión

implica que el inicio del histórico de la demanda deja de ser uniforme para todos los productos. Sin embargo, esto no supone un inconveniente, ya que cada serie temporal conserva suficiente información para capturar sus patrones de comportamiento.

3.3.2. Transformación

Con los objetivos de capturar los patrones semanales y mensuales de la demanda, se han generado variables temporales a partir del atributo *fecha*. En este sentido, se han extraído el día de la semana y el mes de cada observación. Estas variables categóricas han sido posteriormente codificadas mediante un esquema de tipo *one-hot encoding*, dando lugar a atributos binarios como *Domingo* o *Enero*.

3.4 Clustering

El conjunto de datos con el que se ha trabajado contiene una gran cantidad de productos que presentan características muy variadas y heterogéneas, hecho que resulta habitual en cualquier empresa.




Figura 3.9: Ejemplos de la demanda histórica de varios productos distintos entre sí.

Tal y como se muestra en la Figura 3.9, algunos de los artículos presentan una demanda mucho mayor que otros, mientras que otros ítems tienen series temporales muy volátiles. Estas diferencias entre los patrones de la demanda provocan que todos los artículos difícilmente puedan pronosticarse de la misma manera. Por lo tanto, se ha considerado adecuado un proceso de segmentación de los productos en grupos en base a sus similitudes. Para ello, se ha empleado el modelo de aprendizaje no supervisado *k-means*. Este algoritmo se basa en la minimización de la varianza dentro de los grupos mediante el cálculo de distancias y centroides.

3.4.1. Construcción de variables por producto

Dado que el objetivo es agrupar productos y no observaciones individuales, los artículos del conjunto de datos se han agregado a nivel de producto, construyendo un conjunto de variables que permiten caracterizar el comportamiento de sus respectivas series temporales. Estas variables incluyen tanto atributos previamente disponibles, como *eurPrecioMedio* o *diasLeadtime*, como métricas agregadas derivadas de la propia demanda. La Tabla 5 muestra un resumen de los campos utilizados para abordar el proceso de *clustering*. Asimismo, cabe destacar que estas variables únicamente se han empleado para agrupar los datos y no se han tenido en cuenta para entrenar los modelos de aprendizaje automático, exceptuando aquellas que pertenecen al conjunto de datos original, como *diasEntrePedidos*, *diasLeadtime* y *eurPrecioMedio*.

Tabla 5: Resumen del contenido del agregado por producto.

Variable	Tipo	Descripción
<i>producto</i>	Entero	Identificador único de cada producto
<i>promedio_ventas</i>	Decimal	Promedio de ventas por ítem
<i>pct_cero_ventas</i>	Decimal	Fracción de demanda baja por artículo
<i>std_ventas</i>	Decimal	Desviación estándar de las ventas
<i>pct_promo</i>	Decimal	Fracción de tiempo en el que un ítem se ofertó
<i>diasEntrePedidos</i>	Entero	Tiempo entre pedidos de un producto en días
<i>diasLeadtime</i>	Entero	Tiempo de entrega de un ítem en días
<i>eurPrecioMedio</i>	Decimal	Precio promedio de un artículo
<i>mejora_promo</i>	Decimal	Diferencia de la media de ventas con y sin promoción

3.4.2. Escalado estándar

Previamente a la aplicación del algoritmo *k-means*, se han normalizado los valores de los atributos de la Tabla 5 mediante un escalado estándar [15]. Esto resulta necesario dado que el algoritmo es sensible a la escala de los datos ya que se basa en distancias euclidianas. Esta transformación se lleva a cabo por medio de la Ecuación 8, que centra las variables, x , en media cero y varianza unitaria, sustrayendo la media del atributo, μ , y dividiendo por la varianza del campo, σ .

$$z = \frac{x - \mu}{\sigma} \quad (8)$$

Asimismo, para visualizar los resultados del *clustering* se ha optado por una proyección en dos dimensiones mediante técnicas de reducción de la dimensionalidad como PCA y

t-SNE.

3.4.3. Selección del parámetro k

Dado que k -means requiere que se fije un número de *clusters*, k , *a priori*, se ha usado el método del codo para hallar el número de grupos óptimo. Tal y como se observa en la Figura 3.10, a partir de cierto valor de k la reducción de la suma de los errores cuadrados respecto a los centroides de cada grupo deja de ser significativa, seleccionándose finalmente $k = 10$ como valor inicial.




Figura 3.10: Suma de los errores cuadrados en función del número de *clusters*.

3.4.4. Aplicación y visualización de los *clusters*

Una vez se han fijado el número de grupos que se deben generar, se ha ejecutado el algoritmo k -means con $k = 10$ y se han visualizado los resultados en un espacio reducido mediante PCA y t-SNE.




Figura 3.11: Proyección de los grupos obtenidos con k -means con PCA (a) y t-SNE (b).

Como se observa en la Figura 3.11, PCA no presenta una separación clara entre los

productos, mientras que la representación obtenida mediante t-SNE revela la presencia de agrupaciones más definidas. Este comportamiento sugiere la existencia de relaciones no lineales entre las variables que no pueden ser capturadas por métodos lineales como PCA. Asimismo, la aparición de estas estructuras en el espacio reducido refuerza la idea de que existen patrones diferenciados entre los productos, lo que justifica la aplicación de técnicas de segmentación.

3.4.5. Interpretación de los *clusters*

Tras haber identificado los grupos de productos más relevantes, se han analizado las características de cada uno en relación con la media global de las variables de la Tabla 5 de todos los artículos. Tal y como se muestra en la Figura 3.12a, esto permite identificar patrones diferenciados de comportamiento entre los ítems del conjunto de datos.




Figura 3.12: (a) Diferencias entre los *clusters* y la media de todos los productos. (b) Tamaño de cada *cluster*.

En primer lugar, algunos *clusters* como los grupos 1, 5 y 7, concentran un mayor número de productos según la Figura 3.12b. Además, también muestran características muy próximas a la media del conjunto de datos, mostrando patrones de comportamiento similares. Por este motivo, se ha optado por su fusión en un único grupo denominado *estandar*, reduciendo la complejidad del problema sin pérdida significativa de información.

Por otro lado, existen grupos con comportamientos claramente diferenciados, especialmente aquellos asociados a productos con mayor volumen de ventas. En los *clusters* 0 y 6 se observa una cierta similitud entre ellos, si bien uno presenta valores más extremos y menor número de observaciones. Esto ha motivado también su fusión en un solo grupo al que se ha apodado como *top_ventas*.

Asimismo, el grupo 4 presenta artículos con una alta rotación en el inventario y, debido a la falta de similitudes con otros *clusters*, se ha decidido denominarlo *alta_rotacion*. Finalmente, los grupos 2, 3, 8 y 9, presentan un tamaño muy reducido, y en algunos casos comportamientos más específicos o atípicos. Dado que no cuentan con suficientes observaciones para entrenar modelos robustos de forma individual, se ha considerado agruparlos en un único *cluster* llamado *residual*.




Figura 3.13: Proyección de los *clusters* fusionados finales con PCA (a) y t-SNE (b).

De forma adicional, La Figura 3.13 muestra de nuevo la proyección bidimensional tanto con PCA como con t-SNE de los *clusters* finales tras el proceso de fusión. Cabe destacar que las decisiones que se han tomado en cuanto a la fusión de varios grupos también se reflejan directamente en la proyección mediante t-SNE. Los grupos unidos ocupaban previamente regiones próximas en dicho espacio, lo que refuerza la coherencia del proceso seguido y valida la agrupación final obtenida.

Tabla 6: Resumen de los cuatro grupos finales obtenidos tras el proceso de *clustering*.

<i>Cluster</i>	Productos	Muestras	Descripción
<i>estandar</i>	497	362.564	Productos con características próximas a la media de todos los ítems
<i>top_ventas</i>	168	122.418	Artículos con mayor demanda
<i>alta_rotacion</i>	74	54.020	Ítems con más rotación de inventario
<i>residual</i>	83	60.547	Productos con comportamientos y características variadas

Por último, en la Tabla 6 se muestra un breve resumen de los cuatro *clusters* finales

que se han obtenido. Además, es importante comentar el hecho que los distintos grupos presentan tamaños dispares, especialmente el grupo *estandar*, que es el que contiene la mayoría de los productos. No obstante, la fusión de *clusters* se debe realizar en base a similitudes reales entre los artículos y no con el fin de obtener un conjunto de grupos de tamaño uniforme. Asimismo, se ha considerado que cada grupo contiene una cantidad de datos suficiente para poder entrenar un modelo de aprendizaje automático robusto.

3.5 Ingeniería de características

Con el objetivo de capturar la dinámica temporal de las series de demanda y mejorar la capacidad predictiva de los modelos, se han incorporado nuevas variables derivadas a partir de los valores históricos de la demanda. En particular, se han generado variables de retardo que recogen la demanda en periodos pasados, así como variables basadas en ventanas móviles, las cuales se muestran en la Tabla 7. Este procedimiento se ha aplicado tanto al conjunto de datos global como a los subconjuntos definidos en el proceso de *clustering*

Tabla 7: Resumen de las variables derivadas añadidas al conjunto de datos.

Variable	Descripción	Utilidad
lag_i	Valor de la demanda observado i periodos en el pasado	Permite capturar la dependencia temporal
hor_j	Valor de la demanda j periodos en el futuro	Define el objetivo del modelo en un contexto de predicción <i>multi-step</i>
$media_rolling_i$	Media de la demanda en una ventana de i días en el pasado	Modela el nivel reciente de la demanda y suaviza el ruido
$std_rolling_i$	Desviación estándar en una ventana de i días en el pasado	Captura la variabilidad y la volatilidad de la demanda
$max_rolling_i$	Valor máximo en una ventana de i días en el pasado	Facilita la identificación de picos recientes de demanda

Asimismo, también se han construido variables objetivo a distintos horizontes temporales, lo que permite abordar el problema desde una perspectiva de predicción *multi-step*. Este enfoque resulta especialmente relevante en el contexto de la gestión de inventario, donde es necesario estimar la demanda futura durante todo el ciclo de aprovisionamiento de cada producto. Cabe recordar que este ciclo es la suma del periodo de revisión de inventario de un artículo, la variable *diasEntrePedidos* o R , y el tiempo de entrega del producto, el atributo *diasLeadtime* o L . Dado que este ciclo varía entre artículos, se ha optado por definir un horizonte común, h , equivalente al ciclo de aprovisionamiento máximo de cada

conjunto de datos, D , como se muestra en la Ecuación 9. De esta forma se predice desde el periodo futuro inmediato hasta el horizonte máximo del conjunto de datos, h_D .

$$h_D = \max_{i \in D} (L_i + R_i) \quad (9)$$

Por último, se ha considerado que la información más relevante para la predicción se encuentra en el comportamiento reciente de la serie, por lo que las variables de ventana móvil se han calculado utilizando un histórico de 28 días. De esta forma se ha evitado la introducción de ruido asociado a periodos demasiado lejanos. Además, de entre todas estas variables se han seleccionado únicamente aquellas correspondientes a múltiplos de 7 como, por ejemplo, lag_7 , lag_14 , lag_21 y lag_28 . De esta forma se capturan los patrones semanales relevantes en la demanda, reduciendo al mismo tiempo la redundancia entre estas variables, las cuales están altamente correlacionadas. Además, también se reduce el coste computacional asociado al aprendizaje de los modelos y se mejora la interpretabilidad de sus resultados.




Figura 3.14: Matriz de correlaciones de las variables explicativas y los atributos objetivo, hor_j , del conjunto de datos global. Solo se muestran algunos atributos por cuestión de espacio.

La Figura 3.14 muestra la matriz de correlaciones de las variables del conjunto de datos global que incluye todas las series temporales de todos los productos. Tal y como se observa en la visualización, las variables originales del *dataset* no muestran una relación lineal fuerte con ninguno de los horizontes de la demanda en el futuro. En particular,

variables como las promociones o el precio medio presentan correlaciones prácticamente nulas, mientras que otras como el tiempo de entrega o la apertura del establecimiento muestran relaciones ligeramente positivas. Esto sugiere que la demanda no depende de forma lineal de estas variables de manera aislada, sino de interacciones más complejas entre ellas. Esta observación es coherente con los resultados obtenidos en las proyecciones de la Figura 3.11, donde t-SNE, capaz de capturar relaciones no lineales, revela una segmentación más clara que PCA, basado únicamente en relaciones lineales.

Por otro lado, la adición de las variables derivadas de la Tabla 7, como las medias, los máximos y las desviaciones estándar, mejora la señal predictiva al mostrar una mayor correlación con la demanda futura. No obstante, estos atributos presentan también una elevada correlación entre sí, lo que justifica la selección de variables espaciadas en el tiempo para reducir la multicolinealidad. De la misma forma, también existe una relación notable entre los múltiples horizontes de la demanda, lo que refleja una dependencia temporal de la variable objetivo bastante consistente.

3.6 Modelado

El siguiente paso ha consistido en el entrenamiento de los distintos modelos de predicción de la demanda. En este apartado se describen las decisiones metodológicas adoptadas en relación con la selección de modelos, la definición de las métricas de evaluación, el preprocesamiento de los datos específico de cada algoritmo, la partición de los datos y la optimización de los hiperparámetros de cada modelo.

3.6.1. Selección de los modelos

Tal y como se ha expuesto en las conclusiones del estado del arte, se han seleccionado tres modelos representativos de distintos enfoques metodológicos con el objetivo de capturar la complejidad del problema abordado. En particular, se han empleado modelos de tipo *ensemble*, como *Random Forest* y *XGBoost*, y una red neuronal LSTM, diseñada específicamente para capturar dependencias temporales en series de datos. La elección de estos modelos responde a la naturaleza del problema, caracterizado por la presencia de múltiples series temporales heterogéneas y relaciones no lineales entre variables. Asimismo, la literatura también ha demostrado que estos modelos ofrecen buenos rendimientos en contextos de previsión de la demanda. Adicionalmente, también se ha entrenado un modelo *naive* que pronostica la demanda futura como el último valor observado de la serie temporal. Cabe recordar que este enfoque se ha empleado como referencia base para comparar la mejora que aportan los modelos de aprendizaje automático tanto en términos de precisión predictiva como de impacto económico sobre el sistema de inventario.

Asimismo, los modelos se han entrenado tanto sobre el conjunto de datos global como

sobre los subconjuntos definidos mediante el proceso de *clustering*, exceptuando el modelo *naive* que solo se ha entrenado sobre el *dataset* global. Esto ha permitido evaluar si la segmentación de los productos mejora la capacidad predictiva respecto a un enfoque generalista.

3.6.2. Definición de los indicadores de precisión

El rendimiento de los modelos se ha evaluado mediante las métricas RMSE y RMSSE. El RMSE resulta especialmente útil en contextos de previsión de la demanda debido a que penaliza aquellas predicciones que se alejan considerablemente del valor real. Esto resulta especialmente relevante en sistemas de gestión de inventario donde los errores elevados pueden traducirse en pérdidas económicas importantes. Por otro lado, el RMSSE permite comparar el rendimiento de los modelos entre productos con escalas de demanda distintas mediante una versión normalizada del error cuadrático. No obstante, esta métrica no se ha calculado para el modelo *naive* ya que en este caso se ha considerado que no aporta información de valor. Esto se debe a que el denominador del RMSSE se basa precisamente en el error cometido por un enfoque que utiliza la demanda observada en el periodo anterior como predicción futura.

Dado que el problema abordado consiste en la predicción de múltiples horizontes temporales, ambas métricas se han calculado de forma independiente para cada producto, p , y cada horizonte de predicción, h , de la forma $error_{p,h}$. En este caso, *error* referencia tanto el indicador RMSE como el RMSSE. Posteriormente, a partir de la Ecuación 10 se ha calculado un error promedio considerando únicamente aquellos horizontes comprendidos dentro del ciclo de aprovisionamiento de cada producto, definido como la suma del tiempo de entrega, L , y el periodo de revisión, R . Esta decisión se debe a que la demanda de cada producto debe estimarse a lo largo de todo este intervalo temporal.

$$error_p = \frac{1}{R+L} \sum_{h=1}^{R+L} error_{p,h} \quad (10)$$

Seguidamente, mediante la Ecuación 11 se obtiene el rendimiento global de cada modelo promediando los errores operativos de todos los productos, N .

$$error_{modelo} = \frac{1}{N} \sum_{p=1}^N error_p \quad (11)$$

Este enfoque permite evaluar los modelos considerando únicamente aquellos horizontes temporales relevantes desde el punto de vista operativo. De este modo, la evaluación predictiva queda alineada con el contexto real de aplicación del sistema de previsión de la demanda.

3.6.3. Preprocesamiento específico de los modelos

A pesar de que todos los modelos que se han empleado comparten el mismo conjunto de variables derivadas descritas en la sección anterior, cada algoritmo requiere una representación distinta de los datos de entrada en función de su arquitectura y funcionamiento interno. Por este motivo, en este apartado se detalla el preprocesamiento específico aplicado a cada familia de modelos.

Random Forest y XGBoost

En el caso de los modelos basados en árboles de decisión, el preprocesamiento empleado se corresponde directamente con el procedimiento de ingeniería de características descrito en el apartado anterior. De este modo, cada observación del conjunto de datos queda representada mediante un vector compuesto tanto por las variables originales como por las variables temporales derivadas.

LSTM

El preprocesamiento que se ha aplicado a los datos que han alimentado los modelos LSTM difiere ligeramente al que se ha seguido en los modelos basados en árboles. Esto se debe a que las redes neuronales de celdas LSTM no trabajan con observaciones independientes, sino con secuencias ordenadas temporalmente. Por este motivo, los datos se han organizado en tensores tridimensionales.

Para cada producto se han creado ventanas temporales de 28 días en el pasado que contienen tanto las variables originales del conjunto de datos como un conjunto adicional de atributos derivados calculados a partir de la demanda histórica reciente. De la misma forma que en los otros modelos del trabajo, se han calculado estadísticas de ventana móvil como la media, la desviación estándar y el máximo de la demanda para distintos periodos temporales. Estos intervalos se replican a lo largo de toda la secuencia para incorporarlas como variables adicionales de entrada. Asimismo, también se han construido los horizontes de la demanda asociados a cada secuencia, empleando el horizonte más grande de cada *dataset* para obtener un conjunto de datos homogéneo. El resultado de este proceso es un tensor con dimensiones $N \times 28 \times var.$, donde N representa el número de muestras, 28 corresponde al número de periodos pasados que componen cada secuencia, y $var.$ son el número de variables de entrada utilizadas en cada instante temporal.

Seguidamente, las variables de entrada y salida se han normalizado mediante un escalado de tipo *MinMax* con la Ecuación 12 para transformar todos los valores al intervalo $[0, 1]$ [15]. La omisión de este paso provocaría que los atributos con magnitudes muy distintas dominaran el proceso de aprendizaje y dificultarían la convergencia del algoritmo de

optimización, dando lugar a fenómenos como la explosión y la desaparición del gradiente [41].

$$z = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (12)$$

Modelo *naïve*

Este método utiliza únicamente la variable *udsVenta* para predecir la demanda futura a partir del último valor observado de la serie temporal. Por este motivo, no ha requerido la generación de variables derivadas ni transformaciones adicionales sobre los datos.

3.6.4. Definición de los periodos de entrenamiento y validación

La partición de los datos se ha realizado de forma independiente para cada ítem, p_i , preservando el orden cronológico de las observaciones y evitando así un *data leakage*. Para cada serie temporal se han utilizado las observaciones más antiguas para el entrenamiento y las más recientes para la prueba. En el caso del modelo *Random Forest* se ha seguido la partición de la Figura 3.15a. Por otro lado, en los modelos *XGBoost* y *LSTM* se ha reservado el 20 % más reciente del conjunto de entrenamiento de cada producto para construir un conjunto de validación, tal y como muestra la Figura 3.15b. Esto permite monitorizar el proceso de aprendizaje y aplicar técnicas de regularización como *early stopping*. Posteriormente, en ambos casos se han concatenado los subconjuntos generados en cada serie para construir los conjuntos completos que se han usado durante el modelado.




Figura 3.15: Generación de los conjuntos en *Random Forest* (a), y en *XGBoost* y *LSTM* (b).

3.6.5. Elección de hiperparámetros

En este apartado se describe el proceso de optimización de los hiperparámetros que se han escogido en cada modelo de *machine learning*. Además, para un mayor nivel de detalle de este procedimiento, se ha incluido el apartado [A.3](#) en el anexo del trabajo.

Random Forest

La Tabla 8 recoge los hiperparámetros del modelo *Random Forest* que han sido objeto de optimización, junto con el espacio de búsqueda que se ha definido para cada uno de ellos. En particular, se han ajustado parámetros relacionados con la complejidad de los árboles y el proceso de partición de los nodos.

Tabla 8: Hiperparámetros seleccionados y optimizados para *Random Forest*.

Hiperparámetro	Descripción	Espacio de búsqueda
<i>n_estimators</i>	Número de árboles	[100, 200]
<i>max_depth</i>	Profundidad máxima de cada árbol	[5, 7, 10]
<i>max_features</i>	Variables consideradas para dividir un nodo	[sqrt, 0.5]
<i>min_samples_split</i>	Mínimo de muestras para dividir un nodo	[2, 5]
<i>min_samples_leaf</i>	Mínimo de muestras en las hojas después de dividir un nodo	[2, 5]

El proceso de optimización se ha realizado con *RandomizedSearchCV* para explorar de forma eficiente el espacio de búsqueda definido. Este método permite evaluar el rendimiento del algoritmo probando tantas combinaciones aleatorias de hiperparámetros como se especifique.

Durante este procedimiento, el rendimiento de cada configuración se ha estimado mediante validación cruzada temporal utilizando *TimeSeriesSplit* con 5 pliegues y el RMSE como métrica de evaluación. Este procedimiento permite respetar el orden cronológico de las observaciones y evitar el uso de información futura durante el entrenamiento, tal y como se ilustra en la Figura 3.16. No obstante, al tratarse de un problema multiserie donde las observaciones de distintos productos se agrupan en un único conjunto de datos, la validación temporal no preserva completamente la estructura cronológica individual de cada serie temporal. En este sentido, cada estrato de cada pliegue contiene series de varios productos, p_i . A pesar de esta limitación, se ha considerado que el enfoque adoptado proporciona una estimación razonable del rendimiento de los modelos manteniendo un coste computacional asumible.




Figura 3.16: Validación temporal empleada durante la optimización de los hiperparámetros.

XGBoost

La Tabla 9 recoge los hiperparámetros del modelo *XGBoost* que se han optimizado. Este modelo no permite de forma nativa la predicción simultánea de múltiples horizontes de la demanda. Si bien versiones recientes del algoritmo han incorporado soporte para predicción *multi-step*, este enfoque se encuentra todavía en una fase experimental y no está ampliamente consolidado en aplicaciones prácticas [42]. Por este motivo, se ha optado por entrenar un modelo independiente para cada horizonte temporal. No obstante, este planteamiento implica asumir que los distintos horizontes de la demanda son independientes, ignorando parcialmente la correlación existente entre ellos.

Tabla 9: Hiperparámetros seleccionados y optimizados para *XGBoost*.

Hiperparámetro	Descripción	Espacio de búsqueda
<i>max_depth</i>	Profundidad máxima de cada árbol	[5, 7, 10]
<i>learning_rate</i>	Peso de cada árbol en la predicción final	[0.01, 0.05, 0.1]
<i>subsample</i>	Fracción de muestras usadas por árbol	[0.6, 0.8, 1.0]
<i>colsample_bytree</i>	Fracción de variables usadas por árbol	[0.6, 0.8, 1.0]
<i>gamma</i>	Reducción mínima de pérdida para dividir nodos	[0, 0.1, 0.3]

Dado que se han entrenado tantos modelos como horizontes de la demanda, se ha decidido optimizar un subconjunto reducido de modelos distribuidos equitativamente a lo largo del horizonte de predicción. Para ello, también se ha usado *RandomizedSearchCV* junto con la validación temporal que ofrece *TimeSeriesSplit*. A partir de estos resultados, se ha obtenido una configuración común mediante el promedio de los mejores parámetros iden-

tificados en cada caso, la cual se ha aplicado posteriormente al resto de modelos *XGBoost*.

LSTM

Parte de los hiperparámetros optimizados en el modelo LSTM se encuentran en la propia arquitectura de la red entrenada. La Figura 3.17 muestra los distintos bloques que componen esta red neuronal junto con las dimensiones de los tensores de salida de cada capa.




Figura 3.17: Arquitectura de la red LSTM empleada en el proyecto.

La red recibe como entrada secuencias temporales de 28 días de las variables explicativas, dando lugar a tensores de dimensiones $X \in \mathbb{R}^{N \times 28 \times F}$. La red se compone de dos capas LSTM apiladas con H_1 y H_2 celdas, respectivamente. La primera conserva la estructura temporal completa de la secuencia y la segunda resume la información más relevante en una representación compacta. Asimismo, se incorporan capas de regularización *dropout* con probabilidad d para reducir el riesgo de sobreajuste. Posteriormente, la salida de las capas recurrentes se introduce en una capa densa de dimensión D con activación *ReLU*. Este bloque combina de forma no lineal las características temporales extraídas por la red. Finalmente, la capa de salida genera simultáneamente todos los horizontes futuros de la demanda, permitiendo realizar las predicciones *multi-step*.

Dicho esto, se han optimizado los hiperparámetros H_1 , H_2 , D y d , además de la tasa de aprendizaje y el número de *batches*, tal y como muestra la Tabla 10. Asimismo, para llevar a cabo esta tarea se ha optado por emplear la librería *Optuna*, ya que las redes neuronales presentan un espacio de hiperparámetros muy amplio y complejo, donde las interacciones entre ellos son altamente no lineales. Esta metodología permite realizar una búsqueda más eficiente al adaptar la exploración del espacio de hiperparámetros en función de los resultados obtenidos en las iteraciones anteriores.

Tabla 10: Hiperparámetros seleccionados y optimizados para LSTM.

Hiperparámetro	Descripción	Espacio de búsqueda
H_1	Número de celdas de la primera capa LSTM	$[32, 128] \cap \mathbb{Z}$
H_2	Número de celdas de la segunda capa LSTM	$[16, 64] \cap \mathbb{Z}$
D	Número de neuronas de la capa densa	$[32, 128] \cap \mathbb{Z}$
d	Tasa de desactivación de las capas LSTM	$[0.1, 0.5] \cap \mathbb{R}$
<i>learning_rate</i>	Tamaño del paso que da la red durante el proceso de optimización	$[1e-4, 1e-2] \cap \mathbb{R}$
<i>batch_size</i>	Número de muestras procesadas por iteración	$[32, 64, 128]$

Posteriormente, la red final optimizada se ha entrenado durante 50 épocas y se ha configurado *Adam* como optimizador de la función de coste. También se ha configurado una condición de parada basada en el rendimiento del conjunto de validación durante el aprendizaje.

3.7 Evaluación de los modelos

Una vez se han entrenado y evaluado los distintos modelos de previsión de la demanda, se procede con el análisis de los resultados obtenidos. En particular, en esta sección se pone el foco tanto en las métricas de precisión obtenidas como en las diferencias de rendimiento entre los distintos enfoques considerados, incluyendo los modelos globales, los modelos segmentados mediante *clustering* y el modelo *naive*. Finalmente, se discuten las principales conclusiones derivadas de los resultados obtenidos.

3.7.1. Análisis de los resultados de precisión obtenidos

La Tabla 11 recoge los valores globales de RMSE y RMSSE obtenidos para cada modelo y conjunto de datos siguiendo la metodología explicada en apartados anteriores. En términos generales, los tres modelos de aprendizaje automático presentan tendencias de error muy similares entre los distintos grupos de productos, tanto en términos de RMSE como de RMSSE. Este comportamiento sugiere que la dificultad del problema depende en mayor medida de las características intrínsecas de cada conjunto de datos que del algoritmo concreto utilizado. Asimismo, los valores obtenidos muestran que los modelos basados en árboles de decisión tienden a ofrecer un rendimiento ligeramente superior al de la red neuronal LSTM en todos los escenarios evaluados.

En cuanto a los modelos entrenados con los datos de los cuatro *clusters*, el grupo *estandar* presenta los RMSE más bajos de todos. Este resultado indica que los productos de este grupo presentan patrones de demanda relativamente estables y homogéneos, lo

que facilita su predicción. De forma similar, también se obtienen resultados favorables en el *cluster alta_rotacion*. No obstante, el *cluster residual* presenta errores ligeramente más grandes que los otros dos grupos y que los modelos globales. Esto probablemente se debe a la mayor heterogeneidad y ruido presente en este conjunto de productos.

Tabla 11: Métricas de evaluación del error obtenidas por los distintos modelos.

Modelo	Conjunto de datos	RMSE	RMSSE
Random Forest	<i>global</i>	1.7265	0.7030
	<i>cluster estandar</i>	1.4716	0.6946
	<i>cluster top_ventas</i>	2.3949	0.7116
	<i>cluster alta_rotacion</i>	1.5361	0.7141
	<i>cluster residual</i>	1.9152	0.6682
XGBoost	<i>global</i>	1.7677	0.7236
	<i>cluster estandar</i>	1.4669	0.6928
	<i>cluster top_ventas</i>	2.4011	0.7123
	<i>cluster alta_rotacion</i>	1.5337	0.7126
	<i>cluster residual</i>	1.9578	0.6892
LSTM	<i>global</i>	1.8043	0.7273
	<i>cluster estandar</i>	1.4789	0.6971
	<i>cluster top_ventas</i>	2.4675	0.7347
	<i>cluster alta_rotacion</i>	1.5947	0.7415
	<i>cluster residual</i>	2.0224	0.7105
<i>naive</i>	<i>global</i>	2.4493	-

Por otro lado, el *cluster top_ventas* concentra los errores más elevados de todos los modelos evaluados. Este comportamiento se explica a partir del proceso de agrupamiento realizado mediante el algoritmo *k-means*. Los *clusters* no se han construido únicamente en función de la variable objetivo, sino considerando conjuntamente todos los atributos disponibles del conjunto de datos. Como consecuencia, las diferencias entre los grupos *estandar*, *alta_rotacion* y *residual* respecto al volumen de demanda no son especialmente pronunciadas. Esto permite que las variables derivadas basadas en estadísticas de ventana móvil capturen adecuadamente sus patrones temporales. Sin embargo, el grupo *top_ventas* se caracteriza principalmente por presentar niveles de demanda considerablemente superiores y una mayor presencia de picos pronunciados. En este contexto, las variables derivadas

utilizadas durante el entrenamiento, como medias o máximos recientes, tienden a suavizar las predicciones. Esto dificulta la anticipación a cambios bruscos en la demanda, y reduce la capacidad predictiva de los modelos para este grupo de productos.

La hipótesis planteada se ve reforzada en la Figura 3.18, donde se muestra la importancia de las variables empleadas para entrenar el modelo global *Random Forest*. Las decisiones del algoritmo se ven altamente influenciadas por los valores de las variables derivadas de la media móvil, especialmente aquellas asociadas a horizontes temporales más amplios. No obstante, también se aprecia una importancia considerable de las variables relacionadas con el día de la semana, lo que sugiere que el modelo es capaz de aprender patrones temporales recurrentes asociados al comportamiento semanal de la demanda. Esto permite que las predicciones capturen con mayor precisión aquellos periodos donde la demanda disminuye, como ocurre en varios días concretos de la semana.




Figura 3.18: Importancia de las variables del conjunto de aprendizaje en las decisiones del modelo global *Random Forest*.

La Figura 3.19 sirve para respaldar visualmente todas estas observaciones, donde se muestran algunas predicciones realizadas sobre productos pertenecientes al *cluster top_ventas*. Independientemente del algoritmo utilizado, los modelos presentan un comportamiento muy similar. Estos se caracterizan por una clara tendencia a suavizar las predicciones, dificultades para prever los picos de demanda más pronunciados, y una buena anticipación a caídas de la demanda a nivel semanal.

Asimismo, en la Tabla 11 también se observa que los modelos entrenados específicamente para cada *cluster* tienden a obtener errores inferiores a los modelos globales. Este resultado refuerza la hipótesis planteada durante el análisis exploratorio acerca de la existencia de patrones de comportamiento diferenciados entre grupos de productos. Consecuentemente, la segmentación mediante un proceso de agrupamiento sí permite es-

pecializar los modelos y mejorar la capacidad predictiva, exceptuando el grupo *top_ventas* por las razones mencionadas anteriormente.




Figura 3.19: Demanda real frente algunas predicciones de dos productos del *cluster top_ventas* mediante *Random Forest* (a-b), *XGBoost* (c-d), y *LSTM* (e-f).

En cuanto al RMSSE, los resultados muestran diferencias menos pronunciadas entre

modelos y conjuntos de datos que las observadas en RMSE. Esto se debe a que esta métrica normaliza el error respecto a la variabilidad histórica de cada producto, reduciendo parcialmente el impacto de las diferencias de escala entre series temporales. Como consecuencia, aunque las tendencias generales se mantienen parcialmente, aparecen algunas diferencias respecto al análisis basado únicamente en RMSE.

En particular, los modelos entrenados sobre los conjuntos *estandar* y *residual* presentan algunos de los mejores valores de RMSSE. Esto indica que, pese a que el error cometido en determinados productos puede ser elevado, este resulta coherente con la propia variabilidad histórica de las series temporales respectivas. Por el contrario, el *cluster alta_rotacion* obtiene valores de RMSSE ligeramente superiores a pesar de presentar RMSE relativamente bajos, indicando que pequeños errores pueden resultar más significativos en productos con una demanda históricamente más estable.

Por otra banda, todos los modelos presentan valores de RMSSE inferiores a 1, lo que indica que su rendimiento es superior al de un enfoque ingenuo basado en utilizar la demanda observada en el periodo anterior como predicción futura. Esto concuerda con los resultados obtenidos en el modelo *naive*, el cual presenta un RMSE claramente superior al de la mayoría de modelos de aprendizaje automático. Ello indica que los algoritmos entrenados son capaces de capturar parte de la dinámica temporal de la demanda más allá de simplemente extrapolar el último valor observado. No obstante, la diferencia respecto a algunos modelos globales no resulta excesivamente alta, lo que resalta la elevada complejidad del problema de previsión abordado.

3.7.2. Conclusiones de los resultados obtenidos

En base a los resultados expuestos, se pueden extraer varias conclusiones relevantes respecto al problema de previsión de la demanda abordado. En primer lugar, se observa que las diferencias de rendimiento entre los distintos algoritmos empleados son relativamente bajas en comparación con las diferencias existentes entre los distintos grupos de productos. Esto sugiere que la complejidad del problema está más condicionada por la naturaleza de las series temporales y las características de cada conjunto de datos que por la capacidad predictiva específica de los modelos entrenados.

Asimismo, los resultados obtenidos confirman la existencia de patrones de comportamiento diferenciados entre los distintos tipos de artículos. Esto se debe a que, generalmente, los modelos a nivel de grupo presentan un rendimiento superior a los globales. En este sentido, la agrupación permite especializar los modelos y adaptar el aprendizaje a dinámicas de demanda más homogéneas.

Por otro lado, también se destaca la dificultad para anticipar picos de demanda pronunciados en todos los modelos entrenados. Las variables derivadas basadas en ventanas

móviles, aunque permiten capturar adecuadamente tendencias generales y patrones temporales recurrentes, también tienden a suavizar las predicciones. Este comportamiento resulta especialmente evidente en el *cluster top_ventas*, donde la presencia de grandes fluctuaciones reduce significativamente la capacidad predictiva de estos modelos.

Adicionalmente, el análisis conjunto de RMSE y RMSSE permite obtener una visión más completa del rendimiento de los algoritmos. Mientras que el RMSE refleja el impacto absoluto de los errores de predicción, el RMSSE contextualiza dichos errores respecto a la variabilidad histórica de cada producto. Esto permite observar que algunos conjuntos de datos pueden presentar errores relativamente elevados sin que ello implique necesariamente un mal comportamiento relativo del modelo, como es el caso del *cluster residual*.

3.8 Evaluación del impacto económico

Las métricas de precisión permiten evaluar el rendimiento predictivo de los modelos, pero no reflejan directamente el impacto operativo y económico que sus errores pueden generar en un sistema real de gestión de inventario. Por este motivo, en esta sección se ha analizado cómo las diferencias observadas entre los modelos afectan al comportamiento de una política de reposición de inventario.

3.8.1. Simulación del inventario bajo una política de reposición *Order-Up-To* (R, S)

Los resultados obtenidos se han incorporado en una simulación de inventario basada en una política de reposición de tipo *Order-Up-To* (R, S). Esta política se introdujo previamente en el marco conceptual, por lo que en este apartado se detalla únicamente su adaptación al contexto experimental del proyecto. En este sentido, algunos de los parámetros fundamentales de esta política se obtienen directamente a partir de las variables disponibles en el conjunto de datos.

El procedimiento se implementa de forma independiente para cada serie temporal del *dataset* sujeto a la simulación, donde el periodo de revisión, R , corresponde a la variable *diasEntrePedidos* de cada producto, mientras que el tiempo de entrega del proveedor viene dado por *diasLeadtime*, L . De este modo, el ciclo de aprovisionamiento completo de un artículo queda determinado por la suma de ambas variables. Asimismo, el nivel objetivo, S , se calcula siguiendo la formulación presentada en la Ecuación 2, como la suma de la demanda prevista durante el ciclo de aprovisionamiento y un *stock* de seguridad. En cuanto a esta reserva de seguridad, su cálculo se efectúa aproximando la desviación estándar del error de predicción al RMSE asociado al producto que se simula. Este RMSE se computa promediando los errores del artículo a lo largo de todos los horizontes comprendidos dentro de su ciclo de aprovisionamiento, como se expuso en la Ecuación 10. Por otro lado, durante

cada revisión periódica también se calcula la posición de inventario del producto con la Ecuación 1. De esta forma se determina la cantidad de unidades que se deben pedir para elevar el inventario hasta S .

El funcionamiento general de este procedimiento se resume en el Algoritmo 1. En cada fecha de la simulación se actualiza el inventario disponible teniendo en cuenta la recepción de pedidos pendientes y la demanda real observada. En caso que la demanda supere el *stock* disponible, se registra una rotura de inventario junto con las ventas perdidas asociadas. Adicionalmente, en aquellos instantes donde corresponde realizar una revisión del inventario, se estima la demanda futura durante el ciclo de aprovisionamiento utilizando las predicciones generadas por los modelos sujetos a la simulación.

Además, durante todo el proceso también se computan varios indicadores operativos y económicos. Por un lado, se calcula diariamente un coste de almacenamiento proporcional al valor del inventario disponible. Este coste se ha aproximado con la Ecuación 13, como el 5 % del valor del inventario disponible, calculado como el producto del precio medio del producto, P , y el número de unidades de dicho artículo en el almacén, $U_{almacen}$.

$$c_{diario} = 0,05 \cdot P \cdot U_{almacen} \quad (13)$$

Por otro lado, las roturas de *stock* generan un coste asociado a las ventas perdidas, aproximado como el precio medio del producto, P , multiplicado por las ventas perdidas, $y_{perdidas}$, como se muestra en la Ecuación 14.

$$c_{rotura} = P \cdot y_{perdidas} \quad (14)$$

Asimismo, tras ejecutar la simulación sobre todos los artículos de un conjunto de datos concreto, las métricas individuales obtenidas para cada producto se agregan para calcular el coste total de almacenamiento, el coste total de rotura, las ventas totales realizadas y la demanda real total. Esto permite posteriormente comparar el impacto operativo de cada estrategia de predicción. Por otro lado, el inventario inicial de cada producto se inicializa como la suma de la demanda real observada durante el primer ciclo de aprovisionamiento del conjunto de prueba de cada ítem. Esta decisión permite empezar la simulación con un nivel de inventario coherente con el comportamiento esperado de cada artículo, evitando introducir sesgos derivados de valores arbitrarios de *stock* inicial.

Finalmente, la simulación se ha aplicado sobre el mejor modelo entrenado con el conjunto de datos global, los mejores modelos obtenidos para cada *cluster*, y el modelo *naive*. Para esta selección se han utilizado los valores de RMSE mostrados en la Tabla 11, dado que esta métrica es la que se emplea durante la simulación para aproximar la incertidumbre de las predicciones y calcular el *stock* de seguridad. En este sentido, se ha

seleccionado el modelo global *Random Forest*, mientras que para los grupos *top_ventas* y *residual* también se han escogido los modelos *Random Forest*. Por otro lado, para los conjuntos *estandar* y *alta_rotacion* se han seleccionado los modelos *XGBoost*. Todo ello permite analizar si la segmentación previa mediante *clustering* se traduce realmente en una mejora del desempeño operativo y económico respecto a un enfoque global. A su vez, esto también permite comparar los resultados obtenidos con una aproximación predictiva significativamente más simple.

Algoritmo 1: Simulación de una política *Order-Up-To* (R, S)

Input: Predicciones de la demanda y datos relevantes de un producto df , RMSE por horizonte temporal $rmse$, y factor de servicio k

Output: Costes operativos y evolución diaria del inventario

```

1: Calcular:
2:    $R \leftarrow diasEntrePedidos$ 
3:    $L \leftarrow diasLeadtime$ 
4:    $P \leftarrow eurPrecioMedio$ 
5:    $\sigma_{R+L} \leftarrow \frac{1}{R+L} \sum_{h=1}^{R+L} rmse_{p,h}$ 
6: Inicializar el inventario inicial, los pedidos pendientes, y los costes operativos
7: for cada día  $i$  del conjunto de prueba  $df$  do
8:   Recibir los pedidos pendientes
9:   Obtener la demanda real del día y actualizar el inventario
10:  En caso de stockout, registrar las ventas perdidas y los respectivos costes,
       $c_{rotura} \leftarrow P \cdot y_{perdidas}$ 
11:  if  $i$  coincide con un periodo de revisión  $R$  then
12:    Calcular la posición de inventario  $\leftarrow U_{almacen} + U_{pedidos}$ 
13:    Calcular el stock de seguridad,  $SS \leftarrow k \cdot \sigma_{R+L} \cdot \sqrt{R+L}$ 
14:    Obtener la demanda prevista durante el ciclo de aprovisionamiento,  $\hat{y}_{R+L}$ 
15:    Calcular el nivel objetivo,  $S \leftarrow \hat{y}_{R+L} + SS$ 
16:    Realizar un pedido si la posición de inventario es inferior a  $S$ 
17:  Registrar el inventario disponible al final del día,  $U_{almacen}$ 
18:  Calcular los costes diarios de almacenamiento,  $c_{diario} \leftarrow 0,05 \cdot P \cdot U_{almacen}$ 
19: return Costes totales, ventas realizadas, demanda real total, stock disponible a
      lo largo de la simulación

```

3.8.2. Análisis de los resultados de las simulaciones

La Tabla 12 muestra los costes operativos y el nivel de servicio obtenidos tras la aplicación del Algoritmo 1 sobre los mejores modelos de aprendizaje automático entrenados y el modelo *naive*. Cabe destacar que el nivel de servicio se ha calculado como la fracción de la demanda real total que representan las ventas realizadas a lo largo de la simulación.

En términos generales, tanto el mejor modelo global de aprendizaje automático como el enfoque basado en modelos especializados por *cluster* presentan un rendimiento claramente superior al modelo *naive*. Esto confirma la capacidad de los modelos predictivos avanzados para mejorar simultáneamente la eficiencia operativa y el nivel de servicio del sistema de inventario.

Tabla 12: Resultados de las simulaciones del inventario. Los costes se expresan en euros.

Enfoque		Costes <i>stock</i>	Costes <i>stockouts</i>	Costes totales	Nivel de servicio
Mejor	modelo	5881800	178531	6060332	97.04 %
Mejores modelos	global				
	por <i>cluster</i>	6161287	152898	6314186	97.85 %
Modelo <i>naive</i>		10930680	304371	11235052	94.86 %

En particular, el mejor modelo global obtiene el menor coste total de todos los enfoques evaluados, alcanzando un valor aproximado de 6.06 millones de euros, frente a los 6.31 millones del enfoque basado en *clusters* y los más de 11 millones obtenidos por el modelo *naive*. Esto supone una reducción cercana al 46 % respecto al enfoque base, evidenciando el impacto económico que puede tener una previsión de demanda más precisa sobre la gestión del inventario.

Asimismo, el modelo global también presenta los menores costes de almacenamiento, aunque a cambio implica unos costes de rotura ligeramente superiores a los obtenidos mediante el enfoque por grupos. Este comportamiento sugiere que el modelo global adopta una política de inventario más ajustada y eficiente desde el punto de vista económico, manteniendo niveles medios de *stock* más reducidos sin comprometer excesivamente la disponibilidad de producto. Como consecuencia, este enfoque consigue el mejor equilibrio entre costes de almacenamiento y costes asociados a roturas de *stock*.

Por otro lado, los modelos especializados por *cluster* alcanzan el mayor nivel de servicio de todos los enfoques evaluados, satisfaciendo aproximadamente el 97.85 % de la demanda total observada. Este resultado indica que la segmentación previa de productos permite capturar de forma más precisa ciertos patrones de demanda específicos de cada grupo.

Sin embargo, esta mejora en la disponibilidad de producto se obtiene a costa de un incremento considerable de los costes de almacenamiento, ya que el enfoque por *clusters* tiende a mantener inventarios más elevados para garantizar una mayor cobertura de la demanda. En consecuencia, aunque este método reduce más eficazmente las roturas de *stock*, el coste económico total termina siendo ligeramente superior al del modelo global.

En cuanto al modelo *naive*, este presenta claramente los peores resultados en todos los indicadores evaluados. Este comportamiento refleja las limitaciones de utilizar estrategias predictivas excesivamente simples en problemas de previsión de la demanda con alta variabilidad temporal, donde pequeñas mejoras en precisión pueden traducirse en diferencias económicas muy significativas.

Por último, en el apartado A.4 del anexo del trabajo se han incluido algunos de los gráficos que se han obtenido como resultado de las simulaciones a nivel de producto. En este sentido, se han representado el número de existencias de cada artículo calculadas al final de cada día del intervalo de tiempo que abarca la simulación. Este gráfico se ha superpuesto sobre la demanda real de cada ítem, y permite comprender de forma visual las diferencias entre los distintos enfoques que se han comparado en esta sección.

3.8.3. Conclusiones de la evaluación económica

Los resultados obtenidos muestran que la utilización de modelos de *machine learning* permite reducir significativamente los costes operativos del sistema de inventario respecto a enfoques predictivos simples. En particular, el mejor modelo global ofrece el menor coste total de todos los escenarios evaluados, logrando un equilibrio adecuado entre costes de almacenamiento y roturas de inventario. Por otro lado, los modelos especializados por *cluster* demuestran una gran capacidad para mejorar el nivel de servicio y reducir las roturas de inventario, aunque a costa de mantener niveles de *stock* más elevados. Esto sugiere que la segmentación previa de productos constituye una estrategia prometedora desde el punto de vista operativo, especialmente en contextos donde la disponibilidad del producto tenga una importancia prioritaria.

En conjunto, los resultados evidencian que mejoras relativamente moderadas en la precisión predictiva pueden suponer la diferencia entre el ahorro o la pérdida de varios cientos de miles de euros.

4 Conclusiones

4.1 Lecciones aprendidas

La realización de este trabajo ha permitido aplicar de forma práctica gran parte de los conocimientos adquiridos durante el máster en un entorno real de previsión de la demanda utilizando datos empresariales reales. Esto ha permitido apreciar la elevada complejidad que implica trabajar con este tipo de datos, donde aparecen problemas habituales como valores perdidos, inconsistencias, ruido o relaciones poco evidentes entre las variables predictivas y la variable objetivo. Como consecuencia, ha resultado necesario llevar a cabo un proceso de análisis exploratorio e ingeniería de características profundo para poder extraer patrones útiles para el entrenamiento de los modelos.

Asimismo, el desarrollo del proyecto ha permitido comprender la importancia de adquirir un conocimiento detallado tanto de los datos como del propio problema de negocio abordado. En este sentido, el trabajo ha reforzado la idea de que en proyectos reales de ciencia de datos no resulta suficiente disponer únicamente de conocimientos técnicos relacionados con matemáticas, estadística o modelado predictivo. En este sentido, también es fundamental entender el contexto operativo en el que se aplican los modelos. Esto mismo ha permitido comprobar la elevada complejidad inherente de los problemas de previsión de la demanda, especialmente en entornos con alta variabilidad y presencia de comportamientos muy distintos entre productos. En este contexto, el uso de técnicas de *clustering* ha permitido comprender tanto el potencial como las limitaciones de los enfoques basados en segmentación previa de productos para tratar series temporales heterogéneas.

Finalmente, uno de los principales aprendizajes adquiridos durante el desarrollo del trabajo ha sido la importancia de evaluar los modelos desde una perspectiva operativa y económica, y no únicamente mediante métricas de error predictivo. En problemas de gestión de inventario, pequeñas diferencias en precisión pueden traducirse en impactos económicos muy significativos, de forma que modelos aparentemente similares en términos estadísticos pueden generar comportamientos operativos muy distintos. Todo ello ha servido para reforzar la necesidad de interpretar los resultados predictivos dentro del contexto empresarial real en el que serán utilizados.

4.2 Logro de los objetivos

El objetivo principal de este trabajo ha consistido en desarrollar modelos de previsión de la demanda basados en técnicas de aprendizaje automático y analizar sus impactos sobre la gestión económica del inventario. Para alcanzar este objetivo general, se plantearon una serie de objetivos específicos que han sido cumplidos a lo largo del desarrollo del proyecto,

los cuales se listan a continuación.

1. Se ha analizado la problemática de la gestión de inventarios desde una perspectiva empresarial, identificando la relación existente entre la precisión de las predicciones de demanda, el nivel de servicio y los distintos costes operativos. Asimismo, se ha estudiado el funcionamiento de políticas de reposición de tipo *Order-Up-To* (R, S) y su relación con la incertidumbre asociada a la previsión de la demanda.
2. Se ha realizado un proceso completo de análisis exploratorio, preprocesamiento e ingeniería de características sobre los datos históricos de demanda. Esto ha permitido identificar patrones temporales relevantes, segmentar productos mediante técnicas de *clustering*, y construir variables derivadas capaces de mejorar la capacidad predictiva de los modelos.
3. Se han implementado distintos modelos de aprendizaje automático basados en *Random Forest*, *XGBoost*, y redes neuronales LSTM, así como un modelo base *naive*. Posteriormente, todos ellos se han evaluado mediante métricas como RMSE y RMS-SE, permitiendo comparar su capacidad predictiva.
4. Se ha estimado la incertidumbre asociada a las predicciones de cada modelo utilizando el RMSE como aproximación de la desviación estándar del error predictivo. Esta incertidumbre se ha integrado posteriormente en una política de reposición *Order-Up-To*, (R, S) para el cálculo dinámico del *stock* de seguridad para cada producto.
5. Finalmente, se ha evaluado el impacto económico de las distintas estrategias predictivas mediante una simulación de inventario. Los resultados obtenidos muestran que los modelos de aprendizaje automático permiten reducir significativamente los costes operativos respecto al modelo *naive*, además de mejorar el nivel de servicio del sistema de inventario.

4.3 Seguimiento de la planificación y la metodología

Aunque inicialmente se definieron distintas fases y periodos temporales para alcanzar los hitos principales del proyecto, el desarrollo del trabajo ha seguido finalmente un enfoque claramente iterativo.

Uno de los primeros aspectos que evidenció esta necesidad fue el rendimiento inicial de los modelos utilizando únicamente las variables originales del conjunto de datos. Los

resultados obtenidos mostraban una capacidad predictiva limitada, lo que motivó el desarrollo de un proceso más profundo de ingeniería de características mediante variables derivadas basadas en estadísticas de ventana móvil.

Asimismo, la segmentación previa de productos mediante técnicas de *clustering* tampoco se contemplaba inicialmente como parte fundamental del proyecto. Sin embargo, durante el análisis exploratorio se observó una elevada heterogeneidad entre productos, tanto estadísticamente como visualmente mediante proyecciones como PCA y t-SNE. Esto motivó la incorporación de un proceso de agrupamiento que permitiera especializar los modelos según distintos patrones de comportamiento de la demanda.

Por otro lado, también surgieron diversas dificultades técnicas y computacionales no previstas inicialmente. En particular, el algoritmo *XGBoost* no dispone de soporte nativo para predicción *multi-step*, lo que obligó a entrenar modelos independientes para cada horizonte temporal. Del mismo modo, la optimización de hiperparámetros mediante *Optuna* en los modelos LSTM implicó un coste computacional considerable, haciendo necesario limitar el número de configuraciones y experimentos para garantizar la viabilidad del proyecto.

Consecuentemente, el desarrollo del trabajo ha permitido apreciar la elevada complejidad asociada a los proyectos reales de ciencia de datos, donde las decisiones metodológicas dependen en gran medida de los resultados obtenidos durante las distintas etapas de la experimentación.

4.4 Limitaciones del trabajo

A pesar de los resultados obtenidos, el presente trabajo también presenta diversas limitaciones que deben considerarse. Una de las principales se observa en los productos del grupo *top_ventas*, donde los modelos presentan mayores dificultades para anticipar picos pronunciados de demanda. En este sentido, las variables derivadas empleadas durante el entrenamiento, basadas principalmente en estadísticas de ventana móvil, tienden a suavizar el comportamiento reciente de las series temporales. Como consecuencia, los modelos desarrollan predicciones más conservadoras, dificultando la detección de cambios bruscos en la demanda y aumentando el error cometido en aquellos productos con mayores volúmenes de venta. Dado que estos artículos concentran una parte muy importante de la demanda total, pequeñas desviaciones predictivas terminan traducándose en impactos económicos significativos.

Asimismo, esta limitación también refleja la falta de variables capaces de describir adecuadamente determinados factores externos que influyen sobre la demanda. Aunque el conjunto de datos incorpora campos temporales y promocionales básicos, no se dispone

de información adicional que permita explicar completamente parte de la variabilidad observada en ciertos productos, particularmente en aquellos cuya demanda es especialmente elevada.

Por otro lado, la simulación económica desarrollada también simplifica determinados aspectos presentes en sistemas reales de gestión de inventario. En particular, los costes operativos se han aproximado mediante formulaciones simplificadas y la simulación se ha centrado en una única política de reposición. Aunque este enfoque permite analizar adecuadamente el impacto económico relativo de los modelos predictivos, no contempla toda la complejidad logística presente en los entornos empresariales reales.

4.5 Líneas de trabajo futuro

Las limitaciones expuestas anteriormente denotan la importancia de establecer diversas líneas de mejora potenciales que podrían explorarse en trabajos futuros, con el objetivo de aumentar tanto la precisión predictiva como el realismo operativo de la solución desarrollada.

Una de las principales líneas de investigación de cara al futuro consiste en mejorar la capacidad predictiva de los modelos sobre los productos con mayor demanda. En este sentido, sería especialmente interesante incorporar nuevas variables capaces de describir con mayor precisión los factores que originan cambios bruscos en la demanda. Por ejemplo, podrían añadirse variables relacionadas con campañas promocionales más detalladas, eventos externos, o información comercial adicional que permita explicar mejor los picos observados en determinados productos.

Por otro lado, otra posible línea de mejora consiste en integrar directamente criterios económicos durante el propio entrenamiento de los modelos predictivos [39]. En lugar de optimizar únicamente métricas estadísticas tradicionales, podrían emplearse funciones objetivo relacionadas directamente con los costes operativos del sistema de inventario. De este modo, el proceso de aprendizaje estaría orientado no solo a mejorar la precisión de las predicciones, sino también a minimizar el impacto económico derivado de las decisiones de reposición.

Finalmente, también sería interesante desarrollar simulaciones de inventario más complejas que incorporen aspectos adicionales presentes en entornos reales, como múltiples almacenes, costes logísticos más detallados, restricciones de capacidad o diferentes políticas de reposición. Todo ello permitiría aproximar todavía más el comportamiento del sistema desarrollado a situaciones reales de gestión de inventario.

5 Bibliografía

- [1] E. Ortiz-Ospina y N. Lippolis. «Structural transformation: How did today's rich countries become deindustrialized?» Our World in Data. dirección: <https://ourworldindata.org/structural-transformation-and-deindustrialization-evidence-from-todays-rich-countries>
- [2] E. A. Silver, D. F. Pyke y D. J. Thomas, *Inventory and Production Management in Supply Chains*. Taylor & Francis, 2017.
- [3] CRISP-DM Consortium, «CRISP-DM 1.0: Step-by-step data mining guide,» CRISP-DM Consortium, Version 1.0 [Guía metodológica], 2000. dirección: <https://www.semanticscholar.org/paper/CRISP-DM-1.0:-Step-by-step-data-mining-guide-Chapman/54bad20bbc7938991bf34f86dde0babfbd2d5a72>
- [4] Organización de las Naciones Unidas. «Objetivos de Desarrollo Sostenible.» dirección: <https://www.un.org/sustainabledevelopment/es/sustainable-development-goals/>
- [5] T. Gneiting y M. Katzfuss, «Probabilistic Forecasting,» *Annual Review of Statistics and Its Application*, vol. 1, págs. 125-151, 2014. DOI: [10.1146/annurev-statistics-062713-085831](https://doi.org/10.1146/annurev-statistics-062713-085831)
- [6] S. Chopra y P. Meindl, *Supply Chain Management: Strategy, Planning, and Operation*, 6th. Pearson, 2016, ISBN: 9781292093567.
- [7] T. Yamazaki, K. Shida y T. Kanazawa, «An approach to establishing a method for calculating inventory,» *International Journal of Production Research*, vol. 54, n.º 8, págs. 2320-2331, 2016. DOI: [10.1080/00207543.2015.1076179](https://doi.org/10.1080/00207543.2015.1076179)
- [8] P. H. Zipkin, *Foundations of Inventory Management*, 1st. McGraw-Hill/Irwin, 2000, ISBN: 9780256113792.
- [9] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd. OTexts, 2021, ISBN: 9780987507136.
- [10] F. Lazzeri, *Machine Learning for Time Series Forecasting with Python*, 1st. Wiley, 2020, ISBN: 9781119682363.
- [11] R. H. Shumway y D. S. Stoffer, *Time Series Analysis and Its Applications: With R Examples* (Springer Texts in Statistics), 5th. Springer, 2025, ISBN: 9783031705847. DOI: [10.1007/978-3-031-70584-7](https://doi.org/10.1007/978-3-031-70584-7)
- [12] H. Levenbach, *Change and Chance Embraced: Achieving Agility with Demand Forecasting in the Supply Chain*. Delphus Publishing, 2017, ISBN: 9780692945988.

- [13] G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung, *Time Series Analysis: Forecasting and Control* (Wiley Series in Probability and Statistics), 5th. John Wiley & Sons, 2015, ISBN: 9781118675021.
- [14] L. Breiman, J. H. Friedman, R. A. Olshen y C. J. Stone, *Classification and Regression Trees*. Chapman & Hall/CRC, 1984, ISBN: 9780412048418.
- [15] T. Hastie, R. Tibshirani y J. H. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (Springer Series in Statistics), 2nd. Springer, 2009, ISBN: 9780387848570. DOI: [10.1007/978-0-387-84858-7](https://doi.org/10.1007/978-0-387-84858-7)
- [16] W.-Y. Loh, «Classification and Regression Trees,» *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 2011.
- [17] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 2nd. O'Reilly Media, 2019, ISBN: 9781492032649.
- [18] L. Breiman, «Bagging Predictors,» *Machine Learning*, vol. 24, n.º 2, págs. 123-140, 1996.
- [19] L. Breiman, «Random Forests,» *Machine Learning*, vol. 45, n.º 1, págs. 5-32, 2001.
- [20] L. Breiman, «Bias, Variance, and Arcing Classifiers,» University of California, Berkeley, inf. téc. Technical Report 460, 1996.
- [21] J. H. Friedman, «Greedy Function Approximation: A Gradient Boosting Machine,» *The Annals of Statistics*, vol. 29, n.º 5, págs. 1189-1232, 2001.
- [22] T. Chen y C. Guestrin, «XGBoost: A Scalable Tree Boosting System,» en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [23] K. Douaioui, R. Oucheikh, O. Benmoussa y C. Mabrouki, «Machine Learning and Deep Learning Models for Demand Forecasting in Supply Chain Management: A Critical Review,» *Applied System Innovation*, vol. 7, n.º 93, 2024.
- [24] J. L. Elman, «Finding Structure in Time,» *Cognitive Science*, vol. 14, n.º 2, págs. 179-211, 1990.
- [25] S. Hochreiter y J. Schmidhuber, «Long Short-Term Memory,» *Neural Computation*, vol. 9, n.º 8, págs. 1735-1780, 1997.
- [26] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy,» *International Journal of Forecasting*, vol. 22, n.º 4, págs. 679-688, 2006.

- [27] S. Makridakis, E. Spiliotis y V. Assimakopoulos, «M5 accuracy competition: Results, findings, and conclusions,» *International Journal of Forecasting*, vol. 38, n.º 4, págs. 1346-1364, 2022.
- [28] R. Carbonneau, R. Vahidov y K. Laframboise, «Machine Learning-Based Demand Forecasting in Supply Chains,» *International Journal of Intelligent Information Technologies*, vol. 3, n.º 4, págs. 40-57, 2007.
- [29] R. Carbonneau, K. Laframboise y R. Vahidov, «Application of machine learning techniques for supply chain demand forecasting,» *European Journal of Operational Research*, vol. 184, n.º 3, págs. 1140-1154, 2008. DOI: [10.1016/j.ejor.2006.12.004](https://doi.org/10.1016/j.ejor.2006.12.004)
- [30] A. Aamer, L. P. E. Yani e I. M. A. Priyatna, «Data Analytics in the Supply Chain Management: Review of Machine Learning Applications in Demand Forecasting,» *OSCM: An International Journal of Operations and Supply Chain Management*, vol. 14, n.º 1, págs. 1-13, 2021. DOI: [10.31387/oscm0440281](https://doi.org/10.31387/oscm0440281)
- [31] E. Spiliotis, S. Makridakis, A.-A. Semenovoglou y V. Assimakopoulos, «Comparison of statistical and machine learning methods for daily SKU demand forecasting,» *Operational Research*, 2020. DOI: [10.1007/s12351-020-00605-2](https://doi.org/10.1007/s12351-020-00605-2)
- [32] R. V. Joseph, A. Mohanty, S. Tyagi, S. Mishra, S. K. Satapathy y S. N. Mohanty, «A hybrid deep learning framework with CNN and Bi-directional LSTM for store item demand forecasting,» *Computers and Electrical Engineering*, vol. 103, págs. 108-135, 2022. DOI: [10.1016/j.compeleceng.2022.108358](https://doi.org/10.1016/j.compeleceng.2022.108358)
- [33] B. Sri Sai Ramya y K. Vedavathi, «An Advanced Sales Forecasting Using Machine Learning Algorithm,» *International Journal of Innovative Science and Research Technology*, vol. 5, n.º 5, págs. 342-345, 2020.
- [34] K. Namir, H. Labriji y E. H. Ben Lahmar, «Decision Support Tool for Dynamic Inventory Management using Machine Learning, Time Series and Combinatorial Optimization,» *Procedia Computer Science*, vol. 198, págs. 423-428, 2022. DOI: [10.1016/j.procs.2021.12.264](https://doi.org/10.1016/j.procs.2021.12.264)
- [35] M. Ifraz, A. Aktepe, S. Ersöz y T. Çetinyoku, «Demand forecasting of spare parts with regression and machine learning methods: Application in a bus fleet,» *Journal of Engineering Research*, vol. 11, págs. 100-105, 2023. DOI: [10.1016/j.jer.2023.100057](https://doi.org/10.1016/j.jer.2023.100057)

- [36] C.-F. Chien, C.-C. Ku e Y.-Y. Lu, «Ensemble learning for demand forecast of after-market spare parts to empower data-driven value chain and an empirical study,» *Computers and Industrial Engineering*, vol. 185, pág. 109670, 2023. DOI: [10.1016/j.cie.2023.109670](https://doi.org/10.1016/j.cie.2023.109670)
- [37] T. B. Affonso, S. V. Conceição, L. R. Muniz, J. F. d. F. Almeida y J. C. Lima, «A new hybrid forecasting method for spare part inventory management using heuristics and bootstrapping,» *Decision Analytics Journal*, vol. 10, pág. 100415, 2024. DOI: [10.1016/j.dajour.2024.100415](https://doi.org/10.1016/j.dajour.2024.100415)
- [38] S. Wang, Y. Kang y F. Petropoulos, «Combining probabilistic forecasts of intermittent demand,» *European Journal of Operational Research*, vol. 315, págs. 1038-1048, 2024. DOI: [10.1016/j.ejor.2024.01.032](https://doi.org/10.1016/j.ejor.2024.01.032)
- [39] Y. Tadayonrad y A. B. Ndiaye, «A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality,» *Supply Chain Analytics*, vol. 3, pág. 100026, 2023. DOI: [10.1016/j.sca.2023.100026](https://doi.org/10.1016/j.sca.2023.100026)
- [40] H. Dehaybe, D. Catanzaro y P. Chevalier, «Deep Reinforcement Learning for inventory optimization with non-stationary uncertain demand,» *European Journal of Operational Research*, vol. 314, págs. 433-445, 2024. DOI: [10.1016/j.ejor.2023.10.007](https://doi.org/10.1016/j.ejor.2023.10.007)
- [41] Y. Bengio, P. Simard y P. Frasconi, «Learning Long-Term Dependencies with Gradient Descent is Difficult,» *IEEE Transactions on Neural Networks*, vol. 5, n.º 2, págs. 157-166, 1994.
- [42] XGBoost Developers, *Multiple Outputs — XGBoost Documentation*, <https://xgboost.readthedocs.io/en/stable/tutorials/multioutput.html>, Accessed: 2026-05-01, 2025.

6 Glosario

PIB: Producto Interior Bruto

CRISP-DM: *Cross Industry Standard Process for Data Mining*

ODS: Objetivos de Desarrollo Sostenible

ARIMA: *AutoRegressive Integrated Moving Average*

RNN: *Recurrent Neural Network*

LSTM: *Long Short-Term Memory*

MAE: *Mean Absolute Error*

RMSE: *Root Mean Squared Error*

MSE: *Mean Squared Error*

RMSSE: *Root Mean Squared Scaled Error*

kNN: *k-Nearest Neighbors*

MLR: *Multiple Linear Regression*

SVR: *Support Vector Regression*

NMAE: *Normalized Mean Absolute Error*

MLP: *Multi-Layer Perceptron*

BNN: *Bayesian Neural Network*

kNNR: *k-Nearest Neighbors Regression*

CNN-BiLSTM: *Convolutional Neural Network - Bidirectional Long Short-Term Memory*

LR: *Linear Regression*

MAPE: *Mean Absolute Percentage Error*

RMSPE: *Root Mean Square Percentage Error*

ANN: *Artificial Neural Network*

SMAPE: *Symmetric Mean Absolute Percentage Error*

DRPS: *Discrete Rank Probability Score*

DRL: *Deep Reinforcement Learning*

SQL: *Structured Query Language*

PCA: *Principal Component Analysis*

t-SNE: *t-distributed Stochastic Neighbor Embedding*

ReLU: *Rectified Linear Unit*

GPU: *Graphics Processing Unit*

A Anexo

A.1 Herramientas para la realización del trabajo

Para el desarrollo del proyecto se han utilizado distintos recursos de *software* y *hardware* orientados al análisis de datos y al entrenamiento de modelos de aprendizaje automático.

Python ha sido el lenguaje de programación empleado en todas las fases del proyecto, utilizando la distribución *Anaconda* para la gestión de entornos y dependencias. Para la implementación y ejecución del código se han utilizado principalmente *Jupyter Notebooks*. Asimismo, el entrenamiento de los modelos LSTM se ha realizado mediante *Google Colab* debido a las mayores necesidades computacionales de este tipo de arquitecturas, aprovechando las GPU gratuitas proporcionadas por la plataforma. Todo el código fuente y *notebooks* desarrollados durante el trabajo se encuentran subidos en un repositorio de *GitHub*¹.

La Tabla 13 muestra las versiones de las distintas librerías de código que se han empleado a lo largo del proyecto. Durante las fases de análisis exploratorio, preprocesamiento y visualización de los datos se han utilizado principalmente *Pandas*, *NumPy*, *Seaborn* y *Matplotlib*. Posteriormente, para la implementación y entrenamiento de los modelos predictivos se han empleado *Scikit-Learn*, *XGBoost* y *TensorFlow*. Asimismo, la optimización de hiperparámetros en los modelos LSTM se ha llevado a cabo mediante la biblioteca *Optuna*.

Tabla 13: Versiones de las soluciones de *software* empleadas en el trabajo.

Python	Pandas	Numpy	Seaborn	Matplotlib	Scikit-Learn	XGBoost	TensorFlow	Optuna
								
3.12.3	3.0.1	2.4.3	0.13.2	3.10.8	1.7.1	3.2.0	2.21.0	4.6.0

A.2 Reconstrucción de *bolOpen* y *bolHoliday*

Las variables *bolOpen* y *bolHoliday* se han reconstruido a partir de la información disponible de marzo de 2024 al mismo mes de 2025. Durante este periodo se han registrado aquellas fechas que la empresa considera como días festivos, y si la tienda abrió esos días. Se ha asumido que el comportamiento en los años consiguientes es el mismo que el observado en este intervalo. La Tabla 14 muestra estos registros para todas las festividades identificadas en las series temporales del juego de datos.

¹https://github.com/mrodriguezsoler/prevision_demanda

Tabla 14: Festividades y aperturas del punto de venta de la empresa de marzo de 2024 hasta marzo de 2025.

Fechas	Festividades	¿Se considera festivo por la empresa?	¿Abrió el punto de ventas?
2024-03-29	Viernes santo	Sí	No
2024-04-01	Lunes de Pascua	Sí	No
2024-05-01	Día del trabajador	Sí	No
2024-05-20	Segunda Pascua	Sí	No
2024-05-31	Día propio de la empresa	Sí	No
2024-06-24	San Juan	Sí	Sí
2024-08-15	Día de la Asunción de la Virgen María	Sí	No
2024-09-11	Diada de Cataluña	Sí	No
2024-10-12	Fiesta nacional de España	Sí	Sí
2024-11-01	Todos los Santos	Sí	Sí
2024-12-06	Día de la constitución española	No	No
2024-12-08	Día de la Inmaculada Concepción	No	No
2024-12-25	Navidad	Sí	No
2024-12-26	San Esteban	Sí	No
2025-01-01	Año nuevo	Sí	No
2025-01-06	Día de reyes	Sí	No

A.3 Detalles de la optimización de los hiperparámetros

En este apartado se han incluido los resultados del proceso de optimización de los hiperparámetros de todos los modelos entrenados a lo largo del presente trabajo. Las Tablas 15, 16 y 17, recogen los mejores parámetros obtenidos tras el proceso de optimización de los algoritmos *Random Forest*, *XGBoost* y *LSTM*. Estos datos se incluyen tanto para los modelos globales como para los modelos por *cluster*. De forma adicional, también se ha añadido el tiempo total que ha durado este procedimiento.

Para la optimización de los algoritmos *Random Forest* y *XGBoost* se ha usado el método *RandomizedSearchCV*. El número de configuraciones totales se ha limitado a 20 para encontrar un equilibrio entre precisión predictiva y eficiencia computacional. Esto resulta especialmente relevante en el caso de *Random Forest*, donde este enfoque de optimización ha durado más de tres horas en el caso del conjunto de datos global. Además, como se detalló en el apartado correspondiente, la optimización se ha llevado a cabo usando validación cruzada temporal con *TimeSeriesSplit* usando 5 pliegues. Esto aumenta la duración de la validación de cada configuración de forma significativa, lo que refuerza la importancia de haber escogido *RandomizedSearchCV* por delante de otros métodos de búsqueda exhaustiva como *GridSearchCV*.

Por otro lado, la optimización de hiperparámetros de la red *LSTM* se ha realizado mediante la librería *Optuna*. En este caso se ha optado por una estrategia de búsqueda basada en optimización bayesiana debido a la gran complejidad del espacio de búsqueda. Durante el procedimiento, cada configuración de hiperparámetros se ha entrenado durante 5 épocas empleando el optimizador *Adam*. Asimismo, con el objetivo de reducir el coste computacional asociado al entrenamiento de múltiples configuraciones, se ha incorporado un mecanismo de *pruning* proporcionado por *Optuna*. Este enfoque permite detener anticipadamente aquellas configuraciones cuyo rendimiento parcial resulta claramente inferior al de otras pruebas realizadas previamente. En total, se han evaluado 50 configuraciones distintas de hiperparámetros para seleccionar la arquitectura final de la red. Esto ha supuesto un coste computacional considerable, por lo que se ha empleado la GPU gratuita que ofrece *Google Colab* para este fin. De todas formas, la duración de este proceso de optimización ha llegado a superar las dos horas en el caso del conjunto global y del *cluster estandar*.

Tabla 15: Resultados de la optimización de los hiperparámetros del modelo *Random Forest*.

Conjunto de datos	<i>n_estimators</i>	<i>max_depth</i>	<i>max_features</i>	<i>min_samples_split</i>	<i>min_samples_leaf</i>	Tiempo (s)
<i>global</i>	200	10	<i>sqrt</i>	2	2	11.087
<i>cluster estandar</i>	200	10	0.5	5	2	5.028
<i>cluster top_ventas</i>	200	10	0.5	2	5	1.174
<i>cluster ata_rotacion</i>	200	10	<i>sqrt</i>	2	5	367
<i>cluster residual</i>	200	10	<i>sqrt</i>	2	2	862

Tabla 16: Resultados de la optimización de los hiperparámetros del modelo *XGBoost*.

Conjunto de datos	<i>max_depth</i>	<i>learning_rate</i>	<i>subsample</i>	<i>colsample_bytree</i>	<i>gamma</i>	Tiempo (s)
<i>global</i>	5	0.07	0.9	0.9	0.2	1.517
<i>cluster estandar</i>	5	0.05	0.8	0.8	0.12	1.052
<i>cluster top_ventas</i>	5	0.05	0.7	0.7	0.06	655
<i>cluster alta_rotacion</i>	5	0.05	0.6	0.6	0	358
<i>cluster residual</i>	10	0.03	0.7	0.6	0.08	365

Tabla 17: Resultados de la optimización de los hiperparámetros del modelo *LSTM*.

Conjunto de datos	Celdas H_1	Celdas H_2	Neuronas <i>dense D</i>	<i>Dropout d</i>	<i>learning_rate</i>	<i>batch_size</i>	Tiempo (s)
<i>global</i>	46	51	104	0.42	6.3e-4	128	7.701
<i>cluster estandar</i>	102	36	107	0.15	7.5e-4	32	10.819
<i>cluster top_ventas</i>	119	39	77	0.13	1.1e-3	32	3.848
<i>cluster alta_rotacion</i>	90	33	115	0.23	1.4e-3	64	1.470
<i>cluster residual</i>	117	53	125	0.14	6.9e-3	64	920

A.4 Visualización de la demanda y del inventario simulado

Esta sección sirve de apoyo visual para comprender los resultados y las conclusiones extraídas de la evaluación del impacto económico de los modelos.




Figura A.1: Demanda real y unidades de dos ítems, calculadas con los resultados del mejor modelo global (a-b), de los mejores modelos por grupo (c-d), y del modelo *naive* (e-f).

La Figura A.1 muestra algunos ejemplos de la evolución del inventario disponible y de la demanda real para distintos productos durante las simulaciones realizadas. En términos generales, se observa que el enfoque basado en modelos por *cluster* tiende a mantener niveles de inventario ligeramente superiores a los del mejor modelo global. Esto permite reducir las situaciones de *stockout* a costa de incrementar los costes de almacenamiento. Por otro lado, el mejor modelo global presenta un comportamiento más equilibrado, manteniendo niveles de *stock* más ajustados y logrando el mejor compromiso entre costes de almacenamiento y costes derivados de roturas de inventario. Finalmente, el modelo *naïve* presenta una clara tendencia a sobreestimar las necesidades de inventario, manteniendo niveles de *stock* considerablemente más elevados durante gran parte de la simulación.